

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
"НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
"ВЫСШАЯ ШКОЛА ЭКОНОМИКИ"
ФАКУЛЬТЕТ КОМПЬЮТЕРНЫХ НАУК**

Смирнов Арсений Сергеевич

МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ

**СРАВНЕНИЕ СТРАТЕГИЙ ОБУЧЕНИЯ С ПОДКРЕПЛЕНИЕМ В ЗАДАЧЕ МАРКЕТ-
МЕЙКИНГА**

Comparison of Reinforcement Learning Strategies in Market Making

по направлению подготовки 01.04.02 Прикладная математика и информатика
образовательная программа «Финансовые технологии и анализ данных»

Научный руководитель
кандидат экономических наук

Наumenko Владимир Викторович

Студент

Смирнов Арсений Сергеевич

Москва 2025

Аннотация

В работе рассматривается задача построения и сравнения стратегий маркет-мейкинга с использованием алгоритмов обучения с подкреплением на основе реальных данных Московской Биржи. Исследование включает разработку и тестирование пяти моделей: Q-Learning, DQN, PPO, SAC и MBPO. Каждая из моделей обучалась и тестировалась на трех различных сегментах финансового рынка: высоколиквидные облигации федерального займа, низколиквидные облигации и акции высокотехнологичной компании. Для обучения использовались расширенные признаки, описывающие состояние стакана, показатели рыночной динамики и позицию агента, а также при тестировании учитывались рыночные задержки исполнения и получения данных. Проведенное сравнение показало, что эффективность моделей существенно зависит от структуры рынка: в условиях высокой ликвидности наилучшие результаты показал алгоритм SAC, в малоликвидной среде лидером стал PPO, а в волатильном сегменте с большим объемом данных — MBPO. Результаты демонстрируют потенциал использования методов обучения с подкреплением для автоматизированного маркет-мейкинга на отечественном финансовом рынке и подчеркивают важность выбора подходящей архитектуры в зависимости от рыночной среды.

Abstract

This study addresses the problem of designing and comparing market-making strategies using reinforcement learning algorithms based on real data from the Moscow Exchange. The research involves the development and testing of five models: Q-Learning, DQN, PPO, SAC, and MBPO. Each model was trained and evaluated across three distinct segments of the financial market: highly liquid government bonds, low-liquidity bonds, and shares of a high-tech company. The training process employed extended features capturing the state of the order book, market dynamics, and the agent's inventory position. During testing, real-world market latencies in data transmission and order execution were taken into account. The results reveal that model performance is highly dependent on market structure: SAC performed best in high-liquidity environments, PPO emerged as the leader in low-liquidity settings, and MBPO outperformed others in volatile markets with large data volumes. These findings highlight the potential of reinforcement learning for automated market-making on domestic financial markets and emphasize the importance of selecting the appropriate model architecture according to the characteristics of the trading environment.

Содержание

Введение.....	5
Глава 1. Теоретическая часть	8
1.1 Основные понятия высокочастотной торговли.....	8
1.2 Классические подходы к решению задачи маркет-мейкинга	10
1.3 Основные понятия обучения с подкреплением.....	13
1.4 Использование моделей обучения с подкреплением в задаче маркет-мейкинга	16
Глава 2. Методология исследования	21
2.1 Реализаций RL-стратегий	21
2.1.1 Модель Q-Learning: обоснование выбора и архитектура.....	21
2.1.2 Модель DQN: обоснование выбора и архитектура.....	26
2.1.3 Модель PPO: обоснование выбора и архитектура.....	28
2.1.4 Модель SAC: обоснование выбора и архитектура	31
2.1.5 Модель MBPO: обоснование выбора и архитектура.....	37
2.1.6 Сравнительная таблица используемых алгоритмов	40
2.2 Реализация симулятора торговли на бирже	41
2.3 Сегментация данных	42
Глава 3. Результаты исследования	44
3.1 Описание данных.....	44
3.2 Результаты моделей в сегменте высоколиквидных ОФЗ.....	45
3.3 Результаты моделей в сегменте низколиквидных ОФЗ	49
3.4 Результаты моделей в сегменте акций	53
Заключение	58
Список использованных источников	63
Приложения	68

Введение

Высокочастотная торговля (High-Frequency Trading, HFT) является одним из самых быстро развивающихся направлений современной финансовой индустрии, характеризующимся использованием передовых алгоритмов и стратегий, направленных на максимизацию прибыли от краткосрочных изменений цены активов [20]. Важной задачей как в рамках HFT, так и долгосрочных стратегий поведения на бирже, является маркет-мейкинг (ММ), заключающийся в постоянном предоставлении ликвидности на финансовых рынках путем регулярного выставления заявок на покупку и продажу. Эффективное решение данной задачи требует не только высокой скорости принятия решений, но и способности адаптироваться к быстро меняющимся рыночным условиям в одних сегментах рынка и умении улавливать средне- и долгосрочные зависимости в других [40].

Развитие методов обучения с подкреплением (Reinforcement Learning, RL) в последние годы продемонстрировало значительные успехи в решении сложных последовательных задач принятия решений. В отличие от традиционных подходов, RL-алгоритмы позволяют агентам самостоятельно обучаться оптимальным стратегиям посредством взаимодействия со средой, что делает их перспективными для решения задач HFT, в частности маркет-мейкинга. Однако несмотря на активное развитие данной области, количество исследований, сравнивающих эффективность различных RL-архитектур применительно к разным сегментам финансового рынка, остается ограниченным, особенно в контексте российского рынка.

Объектом данного исследования являются основные RL-модели различных архитектур, в частности, будут рассмотрены алгоритмы Q-Learning [8], Deep Q-Network (DQN) [26], Proximal Policy Optimization (PPO) [33], Soft Actor-Critic (SAC) [15] и Model-Based Policy Optimization (MBPO) [19]. Выбор этих моделей обусловлен необходимостью покрыть ключевые подходы в обучении с подкреплением: модельные и безмодельные алгоритмы, а также

различные стратегии балансировки разведки и использования полученных знаний.

Предметом исследования выступает эффективность использования перечисленных RL-архитектур для решения задачи маркет-мейкинга на финансовых рынках.

Цель данной работы заключается в комплексной оценке и сравнении эффективности выбранных моделей с различными архитектурными и методологическими характеристиками при решении задачи маркет-мейкинга на примере сегментов данных Московской Биржи¹. Использование именно данных Московской Биржи обеспечивает новизну исследования, так как большинство аналогичных работ базируется на зарубежных рынках, что не всегда отражает специфику российских условий.

Новизна исследования заключается в нескольких аспектах:

1. Разработке и адаптации RL-стратегий на основе реальных данных российского финансового рынка (Московская Биржа).
2. Комплексном сравнении эффективности пяти различных RL-моделей, охватывающих основные современные подходы к обучению с подкреплением.
3. Анализе эффективности применения рассматриваемых алгоритмов в разрезе различных сегментов рынка, что позволит выделить особенности и преимущества конкретных подходов применительно к определённым типам активов или рыночных ситуаций.

Для достижения поставленной цели в работе решались следующие задачи:

1. Обобщены и систематизированы знания в области использования RL-подходов к решению задачи маркет-мейкинга.
2. Предложена методология выбора и построения RL-моделей и торгового симулятора.

¹ <https://www.moex.com/>

3. Предложена сегментация данных для проведения исследования.
4. Собраны и обработаны данные торгов на Московской Бирже по 3 сегментам рынка.
5. Разработаны и обучены 15 моделей обучения с подкреплением.
6. Проведены тестирование и аналитика разработанных моделей на реальных данных.

Результаты данного исследования могут быть полезны как для практического применения в алгоритмическом трейдинге, так и для дальнейшего развития теоретических подходов в области применения методов обучения с подкреплением на финансовых рынках.

Глава 1. Теоретическая часть

1.1 Основные понятия высокочастотной торговли.

В современном мире подавляющее большинство финансовых инструментов торгуется на электронных платформах. Благодаря высокой скорости обработки данных и точности исполнения, все активы, которые часто обращаются в значительных объемах — включая акции, валюту, облигации и деривативы — торгуются преимущественно на электронных рынках [4].

Рыночная заявка представляет собой команду на немедленную покупку или продажу актива по наиболее выгодной цене, доступной в данный момент. Такой тип заявки гарантирует её исполнение, но не позволяет контролировать точную цену сделки. Например, если трейдер размещает рыночную заявку на покупку, система исполнит её по текущей лучшей цене предложения. При продаже — по лучшей цене спроса. Однако следует учитывать, что фактическая цена исполнения может отличаться от цены последней сделки. Рыночные ордера часто называют активными, так как они моментально взаимодействуют с уже существующими заявками на противоположной стороне книги ордеров.

Лимитная заявка, в отличие от рыночного, относится к пассивным. Он содержит не только объём сделки, но и цену, по которой трейдер готов совершить операцию. Такой ордер исполняется лишь при достижении указанного уровня цены — при продаже это минимально допустимая цена, при покупке — максимально приемлемая. Например, если инвестор намерен приобрести акции не дороже определённой суммы, он устанавливает лимитный ордер. Сделка произойдёт только в том случае, если рынок предложит цену, соответствующую заданной или более выгодную.

Кроме рыночных и лимитных ордеров, существует множество других типов заявок, которые обеспечивают гибкость и управление рисками. Среди них:

- Stop-Loss — автоматически активируется как рыночный ордер при достижении определённой цены, защищая от больших убытков;
- Stop-Limit — сочетает свойства стоп-ордера и лимитной заявки;
- Post-Only — гарантирует, что ордер добавится только в книгу заявок, не исполнившись мгновенно;
- All or None (AON) — исполняется только в полном объеме;
- Immediate or Cancel (IOC) — исполняется немедленно, и любая неисполненная часть отменяется.

Все лимитные заявки регистрируются в так называемой книге заявок (Limit Order Book, LOB), которая в русскоязычных источниках нередко называется биржевым стаканом. Эта система представляет собой структурированную таблицу, где отображаются активные лимитные заявки на покупку и продажу, упорядоченные по уровням цен. Информация из стакана доступна участникам торгов и предоставляет представление о текущем спросе и предложении, что способствует более взвешенному принятию решений при совершении сделок [41].

Исполнение заявок на бирже регулируется специальными алгоритмами. Чаще всего используется алгоритм, при котором приоритет отдается рыночным заявкам, затем лимитным — в соответствии с приоритетом цены и временем поступления (FIFO — first in, first out). Рыночный ордер сопоставляется с лучшими доступными лимитными заявками, начиная с наиболее выгодной цены и ранее размещённых ордеров.

Неисполненные лимитные заявки продолжают находиться в книге ордеров до тех пор, пока не произойдут соответствующие рыночные

изменения. Однако FIFO — не единственная схема исполнения. Некоторые торговые платформы используют правило пропорционального распределения (pro-rata rule), при котором входящие рыночные ордера исполняются пропорционально объему доступных лимитных заявок на одной и той же ценовой ступени. В ряде случаев биржи применяют гибридные алгоритмы, сочетающие оба подхода — FIFO и pro-rata — для повышения эффективности и справедливости исполнения.

Одним из ключевых преимуществ электронных торговых систем является их прозрачность. На регулируемых биржах, таких как NASDAQ, NYSE или Московская биржа, данные о заявках и ценах доступны всем участникам. Это способствует формированию справедливой рыночной цены. Однако не все платформы одинаково открыты: некоторые биржи, особенно в случае с альтернативными торговыми системами (dark pools), ограничивают доступ к информации о заявках. Такие организации могут получать доход от продажи данных о потоке ордеров сторонним участникам.

1.2 Классические подходы к решению задачи маркет-мейкинга

Маркет-мейкинг — особая форма торгов, поддерживающая ценовую стабильность, обороты, ликвидность по инструменту и выгодная как Эмитентам, желающим привлечь капитал, так и участникам рынка, заинтересованным в бумаге. Другими словами, задача маркет-мейкинга на финансовом рынке заключается в обеспечении ликвидности путем постоянного выставления котировок на покупку (bid) и продажу (ask) активов. Маркет-мейкеры зарабатывают на спреде между этими ценами, одновременно управляя рисками, связанными с изменениями цен и накоплением позиций [14].

Традиционные модели маркет-мейкинга основываются на аналитических подходах и предполагают определенные допущения о поведении рынка. Долгое время основными моделями для решения этой задачи являлись модель

Авельянеды-Стойкова (Avellaneda-Stoikov) [2] и модель Хо и Столла (Ho & Stoll) [17].

Модель Хо и Столла, представленная в работе “Optimal Dealer Pricing Under Transactions and Return Uncertainty” [17], является одной из первых формализованных моделей поведения дилера на финансовом рынке и заложила фундамент для последующего развития теории маркет-мейкинга. Она описывает дилера, предоставляющего ликвидность на рынке, и стремящегося максимизировать ожидаемую полезность от конечного богатства, принимая во внимание как ценовой, так и объемный риск.

В модели предполагается, что дилер котирует цены покупки и продажи, по которым он готов совершать сделки, и эти котировки определяют вероятность поступления соответствующих заявок от участников рынка. Исполнение заявок моделируется стохастически: чем ближе цена к рыночной, тем выше вероятность исполнения, и наоборот. Таким образом, дилер должен находить баланс между узким спредом (который увеличивает вероятность сделок, но повышает риск) и широким спредом (который снижает риск, но и вероятность исполнения заявок).

Центральным элементом модели является управление инвентарным риском — дилер несёт риск изменения стоимости своей позиции в активах, и в зависимости от её размера он будет стремиться сместить котировки так, чтобы увеличить вероятность сделок в направлении, снижающем риск (например, при переполненном лонге — стимулировать продажи, предлагая более низкие цены покупки).

Модель Авельянеды-Стойкова является одной из основополагающих теоретических конструкций в области высокочастотного маркет-мейкинга. В статье “High-frequency trading in a limit order book” [2] Авельянеда и Стоиков рассматривают поведение маркетмейкера, торгующего на рынке с лимитными заявками, и предлагают аналитическую структуру для определения оптимальных котировок на покупку и продажу с учетом рыночного риска и инвентарного риска.

Основное предположение модели заключается в том, что рыночная цена актива ведет себя согласно случайному блужданию. Маркетмейкер в этом случае выставляет лимитные заявки, которые исполняются случайным образом, и их интенсивность зависит от того, насколько далеко эти котировки находятся от текущей рыночной цены. При этом модель учитывает ограничение на размер позиции: если инвентарь достигает предельного значения, маркетмейкер прекращает предлагать ликвидность на соответствующей стороне рынка.

Ключевая цель маркетмейкера — максимизировать ожидаемую экспоненциальную полезность своего окончательного состояния (сумма наличных и стоимости оставшегося инвентаря), принимая во внимание риск, связанный с неисполнением заявок и колебаниями рыночной цены. Для этого решается задача динамического программирования, в результате чего выводятся аналитические формулы для оптимальных цен покупки и продажи.

Решение показывает, что оптимальные котировки состоят из трёх компонентов: текущей рыночной цены, корректировки, зависящей от склонности маркетмейкера к риску и параметров исполнения заявок, и поправки, отражающей текущую позицию по активу (инвентарь). Таким образом, стратегия маркетмейкера строится на двухэтапной логике: сначала он определяет персональную «индифферентную» цену на основе текущего инвентаря, а затем определяет спред, оптимизируя вероятность исполнения заявок и компенсацию за принятый риск.

Эта модель оказала большое влияние на развитие алгоритмического трейдинга, так как она позволяет формально описать поведение маркетмейкера и учитывать ключевые факторы — волатильность, риск и ликвидность.

В дальнейшем основное место в решении задачи маркет-мейкинга занимали модели, основанные на обучении с подкреплением.

1.3 Основные понятия обучения с подкреплением

Обучение с подкреплением (reinforcement learning или RL) — это подход в машинном обучении, при котором автономная система, называемая агентом (agent), взаимодействует с окружающей средой (environment) и учится принимать оптимальные решения на основе обратной связи, получаемой в результате совершённых действий. Основная цель агента — достигать максимальной общей награды, минимизируя издержки и потери. Процесс обучения происходит по принципу проб и ошибок, без предоставления заранее размеченных обучающих данных.

В отличие от обучения с учителем (supervised learning), где агенту предоставляется набор входных данных и соответствующих правильных ответов (пар "признаки — метка"), в RL таких данных нет. Агент сам должен определить, какие действия ведут к желаемому результату. Также RL-агент сталкивается с фундаментальной дилеммой: эксплуатация (exploitation), то есть использование изученных ранее стратегий, или исследование (exploration) — поиск новых решений, потенциально более эффективных для решения задачи при более длительном горизонте наблюдения результатов. Баланс между этими двумя подходами критически важен для успешного обучения и является одним из факторов отличия моделей друг от друга.

Большинство задач в RL моделируются как марковские процессы принятия решений, которые состоят из конечного множества состояний и действий. Эти модели предполагают, что текущее состояние среды содержит всю необходимую информацию для предсказания будущего, то есть выполняется марковское свойство. Переходы между состояниями и соответствующие награды описываются вероятностными функциями, которые, как правило, считаются стационарными во времени.

Однако во многих реальных задачах, таких как маркетинг или торговые стратегии, агент не может наблюдать полную картину среды. В таких случаях используется более общая модель — частично наблюдаемый

марковский процесс принятия решений (POMDP). В POMDP агент получает не сами состояния, а наблюдения, которые лишь частично отражают истинное состояние среды, усложняя задачу принятия решений и увеличивая требования к памяти и стратегии.

Формальные компоненты RL:

- Пространство состояний (S) — все возможные состояния среды, в которых может оказаться агент.
- Пространство действий (A) — все возможные действия, которые агент может предпринять в каждом состоянии.
- Награда (R) — численный сигнал обратной связи от среды, который агент получает после выполнения действия. Эта величина отражает, насколько успешным было действие с точки зрения поставленной цели.

Механизм взаимодействия.

В каждый момент времени t агент находится в состоянии $s_t \in S$, выбирает действие $a_t \in A(s_t)$, переходит в новое состояние s_{t+1} , и получает награду r_t . Таким образом, агент строит стратегию поведения — политику (policy), обозначаемую как $\pi: S \rightarrow A$, которая определяет правило выбора действий на основе текущего состояния. Цель — максимизировать суммарную награду, либо в виде конечной суммы $R = r_0 + r_1 + \dots + r_n$, либо в виде дисконтированной суммы $R = \sum_{t=0}^{+\infty} \gamma^t r_t$, где $\gamma \in [0,1]$ — дисконтирующий множитель, отражающий предпочтение немедленной награды перед отдалённой.

Подход model-free.

Одна из ключевых концепций в RL — это обучение без модели среды (model-free learning). При таком подходе агент не имеет доступа к структуре среды (например, к функциям переходов или распределениям наград) и обучается исключительно на основе собственного опыта. Он формирует политику, итеративно корректируя её на основе результатов своих действий.

Model-free RL делится на несколько категорий:

- Value-based методы (например, Q-learning, SARSA): агент оценивает ценность состояний или пар «состояние-действие» (value functions), и извлекает политику на основе этих оценок.
- Policy-based методы (например, REINFORCE): агент напрямую оптимизирует параметры политики, максимизируя целевую функцию $J(\pi)$, не прибегая к построению value-функций:

$$J(\pi) = \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^{+\infty} \gamma^t r_t \right] \quad (1.1)$$

где:

- τ — траектория (последовательность состояний, действий и наград);
 - r_t — награда на шаге t ;
 - $\gamma \in [0,1]$ — дисконтирующий множитель, который уменьшает значение отдалённых наград;
 - $\mathbb{E}$ — математическое ожидание по всем возможным траекториям, возникающим при следовании политике π .
- Actor-Critic методы: комбинируют оба подхода — actor обновляет политику, а critic оценивает ценность действия, используя value-функции.

Каждая из этих категорий имеет свои преимущества. Value-based подходы хорошо работают в дискретных средах с конечным числом действий, в то время как policy-gradient методы подходят для задач с непрерывным пространством действий или в ситуациях, где стратегия должна быть стохастической.

Model-based подходы.

В отличие от model-free алгоритмов, model-based методы опираются на наличие или построение модели среды — то есть аппроксимации функций переходов и/или наград. Такие подходы пытаются формализовать, как именно среда реагирует на действия агента: они моделируют вероятность перехода из одного состояния в другое, а также ожидаемую награду.

Model-based методы могут использоваться в двух сценариях:

1. С известной моделью среды (planning) — когда агент изначально знает правила среды (например, в шахматах). Тогда можно применять методы планирования, такие как алгоритмы динамического программирования (Value Iteration, Policy Iteration).
2. С неизвестной моделью (learning + planning) — агент сначала учится предсказывать поведение среды (через обучаемую модель), а затем применяет эту модель для планирования и оптимизации действий. Такой гибридный подход позволяет агенту учиться более эффективно, особенно в условиях ограниченного взаимодействия с реальной средой.

Преимущества model-based RL:

- Быстрое обучение благодаря возможности симулировать среду.
- Повышенная сэмпл-эффективность — меньшее количество реальных взаимодействий требуется для достижения хорошей производительности.

Недостатки:

- Ошибки в аппроксимации модели могут сильно повлиять на качество стратегии.
- Сложность точного моделирования реальных, высоко стохастических или частично наблюдаемых сред.

Современные алгоритмы, такие как Dyna-Q, MuZero используют model-based RL для достижения выдающихся результатов в задачах планирования и принятия решений.

1.4 Использование моделей обучения с подкреплением в задаче маркет-мейкинга

Остановимся на основных современных работах по применению обучения с подкреплением для задачи маркет-мейкинга.

Одной из первых работ, презентовавших кейс успешного применения RL-стратегий для решения задач ММ стала работа Lim Y.S. и Gorse D. [23]. Авторы рассмотрели маркет-мейкинг как задачу управления или как задачу последовательного принятия решений в среде с частично наблюдаемым состоянием, где среда характеризуется высокой волатильностью и быстрыми изменениями, что делает задачу подходящей для использования RL. Постановка задачи осуществляется в виде марковского процесса принятия решений, а агент (маркет-мейкер) должен на каждом шаге решать, где размещать заявки (bid/ask) на покупку и продажу с учетом текущего состояния книги заявок и собственной позиции. В работе используются Q-learning и SARSA — классические off-policy и on-policy методы обучения с подкреплением. Функция вознаграждения формулируется на основе прибыли с учётом инвентарного риска — то есть риска, связанного с накоплением слишком большого количества актива или обязательств.

Основные идеи предлагаемого авторами подхода:

- Учет инвентарного риска: Авторы включают штрафы за большие позиции в функцию вознаграждения, чтобы сместить поведение агента в сторону нейтральной позиции (если агент слишком долго покупает или продаёт, он накапливает нежелательную позицию).

Статья базируется на симуляторе рыночной среды, приближенном к реальному рынку, но не использует реальные финансовые данные. Имитационная модель воспроизводит потоки ордеров, изменения в книге заявок и исполнение ордеров агента. Агент обучается в этой среде, взаимодействуя с ней в реальном времени.

Статья продемонстрировала, что агент, обученный методом RL, показывает положительную прибыль и адаптируется к изменяющейся рыночной динамике. Он научается выставлять более выгодные цены и балансировать между прибылью и риском инвентаря. RL-подходы превосходят простые популярные стратегии. А также было показано, что

эффективность агента существенно зависит от того, как сформулирована функция вознаграждения — особенно важно учитывать риски инвентаря.

Если предыдущая рассмотренная статья использовала достаточно простые RL-модели, то в работе "Deep Reinforcement Learning for High-Frequency Market Making" [21] использовались более продвинутые методы глубокого обучения с подкреплением. Автор применяет глубокие рекуррентные Q-сети (Deep Recurrent Q-Networks, DRQN), которые позволяют учитывать временные зависимости в данных и более точно моделировать поведение агента в условиях частично наблюдаемой среды. В статье также используется симулятор лимитного ордербука для создания реалистичной торговой среды, в которой агент может обучаться и тестироваться. Но также модель использует уже исторические торговые данные.

Предложенный подход показал превосходство над базовыми и более простыми стратегиями ММ: предложенный подход с использованием DRQN превосходит известные стратегии, основанные на методах обучения с временным различием, по показателям прибыльности и управления рисками. Кроме того, автор исследовал влияние структуры комиссий (maker-taker fees) на качество рынка и прибыльность агента, что позволяет оценить, как изменения в дизайне рынка могут повлиять на поведение маркет-мейкеров. В результате, построенные агенты демонстрируют способность адаптироваться к различным рыночным условиям, эффективно управляя инвентарем и поддерживая стабильную прибыльность.

Статья Джонатана Садигяна «Deep Reinforcement Learning in Cryptocurrency Market Making» представляет собой исследование применения методов глубокого обучения с подкреплением к задаче маркет-мейкинга на криптовалютных рынках. В работе разработана и протестирована структура DRLMM (Deep Reinforcement Learning Market Making), в которой используются алгоритмы на основе градиента политики для обучения агентов, взаимодействующих с симулированной торговой средой.

Основные идеи и подход:

- Использование алгоритмов gradient-policy: в качестве агентов применяются два современных алгоритма обучения с подкреплением — Advantage Actor-Critic (A2C) и Proximal Policy Optimization (PPO).
- Наблюдаемое пространство агента: агент получает информацию из лимитного ордербука (LOB), а также статистику поступления ордеров, включая Trade Flow Imbalance (TFI) и Order Flow Imbalance (OFI).
- Функция аппроксимации: используется многослойный персептрон (MLP) с общей скрытой частью и отдельными выходами для политики и ценности.
- Функции вознаграждения: сравниваются две функции вознаграждения:
 - Positional PnL, которая учитывает как реализованную, так и нереализованную прибыль/убыток;
 - Trade Completion: вознаграждает только за завершённые сделки с учетом заданного порога прибыли.

Для обучения были взяты данные за 8 дней по трем криптовалютным парам: BTC-USD, ETH-USD и LTC-USD. Каждый агент прошел 10 миллионов шагов обучения с использованием повторения действий для ускорения процесса.

В качестве основных результатов исследования отмечаются следующие моменты:

- функция Trade Completion показала более стабильные и высокие доходности по сравнению с Positional PnL;
- агенты, обученные на одной криптовалютной паре, смогли успешно применять свои стратегии на других парах, что свидетельствует о способности к обобщению;
- агенты с такими архитектурами эффективно управляли своими позициями, минимизируя риски, связанные с накоплением активов.

Рассмотренные выше статьи использовали в качестве данных для обучения различные финансовые активы. В статье «Deep Reinforcement Learning for Market Making in Corporate Bonds: Beating the Curse of

Dimensionality» авторы разработали алгоритм маркет-мейкинга на внебиржевом рынке корпоративных облигаций с использованием методов глубокого обучения с подкреплением. Одной из основных проблематик работы стала рассмотрение различий эффективности стратегий для такого сегмента рынка как корпоративные облигации. В отличие от рынков акций, рынок корпоративных облигаций характеризуется низкой ликвидностью и высокой размерностью, что делает традиционные методы неэффективными для решения задач маркет-мейкинга в многомерных пространствах. Кроме того, в статье используется model-based алгоритм типа actor-critic. То есть помимо вопроса о различии применяемых подходов в различных сегментах финансового рынка, авторы также одними из первых продемонстрировали пример успешного использования именно model-based RL-стратегии для решения задачи ММ.

Авторы отметили успешность используемого подхода, а также гораздо меньшее оптимальное число шагов обучения (500) для корпоративных облигаций.

Глава 2. Методология исследования

2.1 Реализаций RL-стратегий

При выборе моделей особое внимание уделялось разнообразию характеристик архитектур, которое пытается полностью охватывать особенности обучения, применения, сложности разработки и поддержки в промышленной среде модели каждого типа. При выборе моделей использовался охват следующих характеристик:

- Тип алгоритма: value-based, policy-based, Actor-Critic и model-based.
- Пространство действий: дискретное и непрерывное.
- Уровень сложности: от простого (Q-Learning) до сложных (SAC, MBPO) в контексте времени обучения, инференса, задействованных ресурсов и количества параметров и гиперпараметров.
- On- или Off-policy алгоритм.

Кроме того, все алгоритмы должны встречаться в исследованиях по финансовым рынкам и, желательно, в работах по решению задачи маркет-мейкинга. По итогу, было выбрано 5 типов архитектур (моделей) для дальнейшего проведения исследования.

2.1.1 Модель Q-Learning: обоснование выбора и архитектура

Выбор Q-Learning и DQN (Deep Q-Network) для исследования в задаче маркет-мейкинга обусловлен их фундаментальной значимостью, разнообразием применений и доказанной эффективностью в финансовых средах.

Q-Learning является базовым алгоритмом RL и основой для многих более сложных методов обучения с подкреплением, что делает его отличной отправной точкой для исследований. Алгоритм легко реализуется и позволяет быстро протестировать гипотезы в симулированной среде. Используемая архитектура встречалась ранее в работах Spooner [35].

Далее подробно рассмотрим полную архитектуру Q-Learning модели.

Пространство состояний среды и агента.

Для Q-Learning было выбрано упрощенное, но информативное пространство среды. Пусть состояние среды в момент времени t описывается вектором $s_t \in \mathbb{R}^n$, включающим:

- m_t - средняя рыночная цена в момент времени t .
- $spread_t$ — нормированный спред:

$$spread_t = \frac{p_t^{bid} - p_t^{ask}}{m_t} \quad (2.1)$$

где:

- p_t^{bid} — цена заявки на покупку в момент времени t ;
- p_t^{ask} — цена заявки на продажу в момент времени t ;
- m_t — средняя рыночная цена в момент времени t .
- $price_level_dist_t^{bid,i}$, $price_level_dist_t^{ask,i}$ — расстояния от i -го уровня ask/bid до средней цены:

$$price_level_dist_t^{bid/ask,i} = \frac{p_t^{bid/ask,i}}{m_t} - 1 \quad (2.2)$$

где:

- i — уровень стакана (для данной модели $i = 1$);
- $p_t^{bid/ask,i}$ — цена заявки на покупку/продажу на i -ом уровне стакана в момент времени t ;
- m_t — средняя рыночная цена в момент времени t .
- $notional_t^{bid,1}$, $notional_t^{ask,1}$ — совокупная условная стоимость на 1-ом уровне стакана:

$$notional_t^{bid,i} = p_t^{bid,i} * q_t^{bid,i} \quad (2.3)$$

$$notional_t^{ask,i} = p_t^{ask,i} * q_t^{ask,i} \quad (2.4)$$

где:

- i — уровень стакана (для данной модели $i = 1$);

- $p_t^{bid,i}$ — цена заявки на покупку на i -ом уровне стакана в момент времени t ;
 - $p_t^{ask,i}$ — цена заявки на продажу на i -ом уровне стакана в момент времени t ;
 - $q_t^{bid,i}$ — объем заявки на покупку на i -ом уровне стакана в момент времени t ;
 - $q_t^{ask,i}$ — объем заявки на продажу на i -ом уровне стакана в момент времени t .
- OFl_t — order flow imbalance [29], то есть показатель изменения в спросе и предложении на актив:

$$OFl_t = I_{\{p_t^{bid} \geq p_{t-1}^{bid}\}} q_t^{bid} - I_{\{p_t^{bid} \leq p_{t-1}^{bid}\}} q_{t-1}^{bid} - I_{\{p_t^{ask} \leq p_{t-1}^{ask}\}} q_t^{ask} + I_{\{p_t^{ask} \geq p_{t-1}^{ask}\}} q_{t-1}^{ask} \quad (2.5)$$

где:

- p_t^{bid}, p_{t-1}^{bid} — цены заявок на покупку в моменты времени $t, t - 1$;
 - p_t^{ask}, p_{t-1}^{ask} — цены заявок на продажу в моменты времени $t, t - 1$;
 - q_t^{bid}, q_{t-1}^{bid} — объемы соответствующих заявок на покупку в моменты времени $t, t - 1$;
 - q_t^{ask}, q_{t-1}^{ask} — объемы соответствующих заявок на продажу в моменты времени $t, t - 1$.
- RSI_t^{1-min} — масштабированный RSI [25] для временного окна в 1 минуту. Индекс относительной силы (RSI) отражает соотношение положительных и отрицательных изменений цены финансового инструмента за промежуток времени. Эта формула отличается от классической формулы RSI тем, что используются суммы приростов и убытков, а не скользящие средние, а также значение RSI масштабируется в интервал $[-1,1]$, тогда как в классическом RSI — в $[0,100]$:

$$RSI_t = \frac{gain_t - |loss_t|}{gain_t + |loss_t|} \quad (2.6)$$

$$gain_t = \sum_{n=0}^w I_{\{\Delta m_n > 0\}} * \Delta m_n \quad (2.7)$$

$$loss_t = \sum_{n=0}^w I_{\{\Delta m_n < 0\}} * \Delta m_n \quad (2.8)$$

$$\Delta m_n = \frac{m_{t-n}}{m_{t-n-1}} - 1 \quad (2.9)$$

где:

- m_t — средняя рыночная цена в момент времени t ;
 - Δm_n — относительное изменение цены на момент времени $t - n$;
 - w — ширина окна в минутах (для данной модели $w=1$);
 - $gain_t$ — сумма положительных изменений цен за окно ширины w ;
 - $loss_t$ — сумма отрицательных изменений цен за окно ширины w .
- $inventory_t \in [-1; 1]$ — текущий инвентарь агента (позиция). Данный коэффициент представляет собой количество запасов ic , выраженное в процентах от максимального количества запасов IM , который задаётся как гиперпараметр:

$$inventory_t = \frac{ic_i}{IM} \quad (2.10)$$

Пространство действий.

Агент может либо ничего не делать, либо выставить лимитные заявки на покупку/продажу на различных уровнях глубины стакана. То есть действие агента описывается отсутствием действия ($a = 0$) или постановкой одновременно bid и ask заявок на уровнях ($a_{bid/ask,t} = \{1, 3, 5\}$). Заявки могут быть как симметричными ($a_{bid,t} = a_{ask,t}$), так и асимметричными ($a_{bid,t} \neq a_{ask,t}$).

Общее дискретное пространство действий выглядит следующим образом: выбирается одна из следующих 10 стратегий, представленных в таблице 2.1. То есть у агента есть возможность выбрать: будет ли он выставять заявку или нет. Если да, то будет она симметричная и на каком уровне стакана со сторон ask и bid.

Таблица 2.1 – Стратегии выставления заявок агентом

	Уровни стакана									
Ask	0	1	1	1	3	3	3	5	5	5
Bid	0	1	3	5	1	3	5	1	3	5

Функция награды.

Используется популярная в научных работах PnL-ориентированная функция награды с штрафом за риск (см. формулу 2.14).

$$r_t = \Delta m_t * inventory_t + PNL_t^{realized} - \alpha * |inventory_t| \quad (2.11)$$

где:

- $\Delta m_t = \frac{m_t}{m_{t-1}} - 1$ — изменение средней рыночной цены на шаге t ;
- $inventory_t$ — позиция агента (запасы) на шаге t ;
- $PNL_t^{realized}$ — реализованная прибыль (убыток) на шаге t ;
- α — коэффициент штрафа за риск (настраиваемый гиперпараметр).

Выбранная функция поощряет сделки, приносящие прибыль, но штрафует за избыточную экспозицию (риск запасов или инвентарный риск).

Алгоритм обучения.

Q-Learning оптимизирует функцию ценности $Q(s, a)$, описывающую ожидаемую дисконтированную награду при выборе действия a в состоянии s :

$$Q(s_{t+1}, a_{t+1}) \leftarrow Q(s_t, a_t) + \eta \left[r_t + \gamma * \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t) \right] \quad (2.12)$$

где:

- $\eta \in (0, 1]$ — скорость обучения (learning rate);
- $\gamma \in [0, 1)$ — коэффициент дисконтирования;
- r_t — награда на шаге t .

Для выбора действий используется ϵ -жадная стратегия:

$$a_t = \begin{cases} \arg \max_a Q(s_t, a) & \text{с } P = 1 - \epsilon \\ \text{random}(a) & \text{с } P = \epsilon \end{cases} \quad (2.13)$$

2.1.2 Модель DQN: обоснование выбора и архитектура

DQN (Deep Recurrent Q-Networks) использует нейронные сети для обработки сложных и высокоразмерных данных, что делает его подходящим для реальных финансовых рынков. Использование опыта повторного воспроизведения и замороженных целевых сетей улучшает стабильность обучения. Подходит для задач с дискретными пространствами действий, таких как выбор ценовых уровней для размещения ордеров. Используемая архитектура встречалась, в частности, в работах Vicente [37] и Kumar [21]. Такой подход к решению задачи маркет-мейкинга является одним из самых популярных в последних исследованиях и позволяет использовать передовые методы работы с моделями обучения с подкреплением.

Далее подробно рассмотрим полную архитектуру DQN модели.

Пространство состояний среды и агента.

В DQN мы можем использовать более полное и непрерывное представление состояния, поскольку Q-функция аппроксимируется нейросетью. Предлагаемое пространство состояния $s_t \in \mathbb{R}^n$, где:

- $spread_t$ — нормированный спред (см. формулу 2.1);
- $price_level_dist_t^{bid,i}$, $price_level_dist_t^{ask,i}$ — расстояния от i -го уровня ask/bid до средней цены (см. формулу 2.2), где $i = \{1, 2, \dots, 10\}$;
- $notional_t^{bid,i}$, $notional_t^{ask,i}$ — совокупная условная стоимость на первом уровне стакана (см. формулы 2.3, 2.4), где $i = \{1, 2, \dots, 10\}$;
- OFl_t — order flow imbalance, то есть показатель изменения в спросе и предложении на актив (см. формулу 2.5);
- RSI_t^{1min} — масштабированный RSI для временного окна в 1 минуту (см. формулу 2.6);
- $inventory_t \in [-1; 1]$ — текущий инвентарь агента (позиция) (см. формулу 2.10);
- m_window_t — скользящее окно размера 5 для средней рыночной цены.

Пространство действий.

Аналогично модели Q-Learning: $a_{bid/ask,t} = \{0, 1, 2, \dots, 10\}$.

Функция награды.

Аналогично модели Q-Learning (см. формулу 2.11).

Архитектура нейронной сети.

Архитектура нейронной сети представлена на рисунке ниже.




Рис. 2.1. Архитектура нейронной сети для DQN

Алгоритм обучения.

Обновление Q-функции в DQN происходит по следующей формуле:

$$L(\theta) = \mathbb{E}_{(s_t, a_t, r_t, s_{t+1}) \sim \mathcal{D}} \left[\left(r_t + \gamma \max_{a'} Q_{\theta^-}(s_{t+1}, a') - Q_{\theta}(s_t, a_t) \right)^2 \right] \quad (2.14)$$

где:

- θ - параметры онлайн-сети (Q-сети);
- θ^- - параметры таргет-сети (замороженные веса копии Q-сети, которые обновляются реже);
- s_t – состояние среды в момент времени t ;

- s_{t+1} – состояние среды в момент времени $t + 1$;
- a_t – действие агента в момент t ;
- r_t – награда, полученная после действия a_t ;
- $\mathcal{D}$ – Replay buffer (буфер опыта), который хранит N предыдущих состояний четверки (s_t, a_t, r_t, s_{t+1}) ;
- $\gamma \in [0; 1)$ – коэффициент дисконтирования;
- Q_{θ^-} – Q-значение таргет-сети;
- Q_{θ} – текущее предсказание Q-функции.

То есть формула реализует обновление параметров сети Q, минимизируя разницу между:

- Таргетом: $r_t + \gamma \max_{a'} Q_{\theta^-}(s_{t+1}, a')$
- Текущим предсказанием: $Q_{\theta}(s_t, a_t)$

Это квадратичное отклонение между тем, что «должно быть» (по мнению таргет-сети), и тем, что предсказывает текущая сеть. Тем самым агент учится всё лучше оценивать ценность своих действий.

2.1.3 Модель PPO: обоснование выбора и архитектура

Выбор PPO (Proximal Policy Optimization) для исследования задач маркет-мейкинга обусловлен его способностью эффективно обучаться в условиях высокой стохастичности и сложности, характерных для финансовых рынков. PPO использует механизм "обрезки" (clipping) в своей функции потерь, что ограничивает чрезмерные изменения политики и способствует стабильному обучению. Данная особенность позволяет алгоритму на сложных данных быть более предсказуемым и стабильным, что чрезвычайно важно в решении задачи, особенно при аномальных случаях на рынке. Кроме того, благодаря возможности многократного использования данных из одной и той же траектории, PPO достигает высокой эффективности обучения, что особенно важно в средах с дорогими или ограниченными данными. В отличие от своего предшественника TRPO (Trust Region Policy Optimization), PPO не требует

вычисления гессиана, что упрощает его реализацию и снижает вычислительные затраты при примерном сохранении характеристик стабильности и точности результатов, что является строго лучшей альтернативой среди популярных архитектур policy-based типа. Используемая архитектура встречалась, в частности, в работе Spooner [35].

Далее подробно рассмотрим полную архитектуру PPO модели.

Пространство состояний среды и агента.

Предлагаемое пространство состояния $s_t \in \mathbb{R}^n$, где:

- $spread_t$ — нормированный спред (см. формулу 2.1);
- $price_level_dist_t^{bid,i}$, $price_level_dist_t^{ask,i}$ — расстояния от i -го уровня ask/bid до средней цены (см. формулу 2.2), где $i = \{1, 2, \dots, 10\}$;
- $notional_t^{bid,i}$, $notional_t^{ask,i}$ — условная стоимость на первом уровне стакана (см. формулы 2.3, 2.4), где $i = \{1, 2, \dots, 10\}$;
- OFl_t — order flow imbalance, то есть показатель изменения в спросе и предложении на актив (см. формулу 2.5);
- RSI_t^{1-min} — масштабированный RSI для временного окна в 1 минуту (см. формулу 2.6);
- $inventory_t \in [-1; 1]$ — текущий инвентарь агента (позиция) (см. формулу 2.10);
- m_window_t — скользящее окно размера 5 для средней рыночной цены.

Пространство действий.

Аналогично предыдущим моделям (см. таблицу 2.1).

Функция награды.

Аналогично предыдущим моделям (см. формулу 2.11).

Алгоритм обучения.

PPO обновляет политику $\pi_\theta(a, s)$ с ограничением на скачки (слишком резкие изменения) в параметрах, что предотвращает ухудшение поведения агента.

Алгоритм обучения и работы PPO:

1. Собираем траектории опыта (s_t, a_t, r_t, s_{t+1}) ;
2. Оцениваем Advantage с помощью Generalized Advantage Estimation:

$$\widehat{A}_t = \sum_{l=0}^T (\gamma\lambda)^l \delta_{t+l} \quad (2.15)$$

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t) \quad (2.16)$$

где:

- $\widehat{A}_t$ - обобщённая оценка преимущества на шаге t , которая показывает, насколько действие лучше ожидания;
 - δ_t — temporal difference (отклонение между текущей и следующей оценкой);
 - r_t - вознаграждение, полученное агентом на шаге t ;
 - $V(s_t)$ - оценка ценности состояния, предсказанная критиком;
 - $\gamma \in [0; 1)$ – коэффициент дисконтирования;
 - λ - коэффициент сглаживания: определяет баланс между смещением и дисперсией ($0 \leq \lambda \leq 1$);
 - T - длина траектории (или размер горизонта до терминального состояния).
3. Оптимизируем $\mathcal{L}^{CLIP}(\theta)$ в течение нескольких эпох по следующей формуле:

$$\mathcal{L}^{CLIP}(\theta) = \mathbb{E}_t[\min(r_t(\theta) * \widehat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) * \widehat{A}_t)] \quad (2.17)$$

$$r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)} \quad (2.18)$$

где:

- $r_t(\theta)$ - importance sampling ratio (отношение новой политики к старой);
- $\widehat{A}_t$ — оценка advantage действия a_t в состоянии s_t ;
- ϵ — порог клиппинга.

Функция потерь выбирает минимум между правдоподобием нового действия и его клиппированной версией, чтобы не уходить слишком далеко от старой политики.

2.1.4 Модель SAC: обоснование выбора и архитектура

Модели типа Actor-Critic также являются одними из самых популярных при использовании RL-стратегий в задачах маркет-мейкинга. Среди моделей данного типа в большинстве работ используются A2C (Advanced Actor-Critic) и SAC (Soft Actor-Critic). Между этими двумя архитектурами в работе решено было использовать модель SAC. SAC лучше справляется с котировками, выраженными как реальные числа (например, цена заявки или спред). A2C хоть и может работать с непрерывными действиями, он требует более осторожной настройки и менее стабилен при прочих равных условиях. SAC использует метод off-policy, то есть может переиспользовать опыт, повышая sample efficiency. Это важно в маркет-мейкинге, где обучение может быть дорогим (особенно на исторических данных). В то же время on-policy подход, использующийся в модели A2C, требует сбора новых данных на каждом шаге обновления, что делает обучение более медленным и менее устойчивым в нестабильной среде. Кроме того, SAC использует в своем обучении максимизацию энтропии, что помогает лучше исследовать действия и избегать преждевременной сходимости. Еще одним фактором выбора именно модели SAC, что эта архитектура одна из самых популярных RL-алгоритмов для непрерывных торговых стратегий и широко используется в статьях по маркет-мейкингу и в open-source проектах. В то время как A2C в значительной степени устарел и используется не так часто в более поздних статьях, исследующих именно эффективность тех или иных алгоритмов. Используемая в этом исследовании архитектура встречалась, в частности, в работах Bakshaei [3] и Gašperov и Kostanjčar [12].

Далее подробно рассмотрим полную архитектуру SAC модели.

Пространство состояний среды и агента.

В SAC модели предлагается использовать пространство признаков среды и агента аналогичное модели DQN, поскольку Q-функция также аппроксимируется нейросетью. Предлагаемое пространство состояния $s_t \in \mathbb{R}^n$, где:

- $spread_t$ — нормированный спред (см. формулу 2.1);
- $price_level_dist_t^{bid,i}$, $price_level_dist_t^{ask,i}$ — расстояния от i -го уровня ask/bid до средней цены (см. формулу 2.2), где $i = \{1, 2, \dots, 10\}$;
- $notional_t^{bid,i}$, $notional_t^{ask,i}$ — совокупная условная стоимость на первом уровне стакана (см. формулы 2.3, 2.4), где $i = \{1, 2, \dots, 10\}$;
- OFl_t — order flow imbalance, то есть показатель изменения в спросе и предложении на актив (см. формулу 2.5);
- RSI_t^{1-min} — масштабированный RSI для временного окна в 1 минуту (см. формулу 2.6);
- $inventory_t \in [-1; 1]$ — текущий инвентарь агента (позиция) (см. формулу 2.10);
- m_window_t — скользящее окно размера 5 для средней рыночной цены.

Пространство действий.

Модель SAC предполагает использование непрерывного пространства действий, поэтому необходимо несколько изменить постановку задачи оптимизации стратегий. Предполагается использовать размещение лимитных заявок по ценам:

- Для bid:

$$a_t^{bid/ask} = mid_price_t - \beta_t^{bid/ask} * spread_t \quad (2.19)$$

где: $\beta_t = (\beta_t^{bid}, \beta_t^{ask}) \in [-1, 1]^2$.

То есть агент оперирует расстоянием и направлением размера спреда по разные стороны от средней цены.

Функция награды.

Аналогично предыдущим моделям (см. формулу 2.11).

Архитектура нейронной сети.

Построение модели SAC включает в себя 2 Critic-сети, одну Policy-сеть и Value Target-сеть, архитектуры которых показаны на рисунках ниже.




Рис. 2.2. Архитектура Policy-сети модели SAC




Рис. 2.3. Архитектура Critic-сетей модели SAC

Алгоритм обучения.

Алгоритм обучения модели SAC состоит из следующих шагов:

1. Critic (Q_1, Q_2).

Обновление идет по функции потерь:

$$\mathcal{L}_Q = \mathbb{E}_{(s,a,r,s')} \left[\left(Q_i(s_t, a_t) - \hat{Q}(s_t, a_t) \right)^2 \right] \quad (2.20)$$

$$\hat{Q}(s_t, a_t) = r_t + \gamma * \left(\min(Q_1(s'_t, a'_t), Q_2(s'_t, a'_t)) - \alpha * \log \pi(a'_t | s'_t) \right) \quad (2.21)$$

где:

- s_t – состояние среды в момент времени t ;
- a_t – действие, совершенное агентом в момент времени t ;
- r_t – награда, полученная после действия a_t в состоянии s_t ;
- s'_t – новое состояние среды после перехода;
- $Q_i(s_t, a_t)$ – значение, предсказанное текущей i -й Q-сетью ($i=1,2$);
- $\hat{Q}(s_t, a_t)$ – таргетное Q-значение из Target-сети;

- $Q_1(s'_t, a'_t), Q_2(s'_t, a'_t)$ – значения Q-функций в следующем состоянии;
- $\gamma \in [0; 1)$ – коэффициент дисконтирования;
- $\alpha > 0$ – коэффициент энтропийной регуляризации;
- $\log \pi(a'_t | s'_t)$ – логарифм вероятности действия a'_t , взятого из текущей политики агента π ;
- $a' \sim \pi(\cdot | s')$ – действие, сэмплированное из текущей стохастической политики агента в новом состоянии

2. Actor.

Обновление идет по следующей функции потерь:

$$\mathcal{L}_\pi = \mathbb{E}_{s_t} [\alpha * \log \pi(a_t | s_t) - \min(Q_1(s_t, a_t), Q_2(s_t, a_t))] \quad (2.22)$$

где:

- $\mathcal{L}_\pi$ – функция потерь для Actor;
- s_t – состояние среды в момент времени t ;
- a_t – действие, совершенное агентом в момент времени t ;
- $\alpha > 0$ – коэффициент энтропийной регуляризации;
- $\pi(a_t | s_t)$ – вероятностная политика, из которой сэмплируются действия;
- $a' \sim \pi(\cdot | s')$ – действие, сэмплированное из текущей стохастической политики агента;
- $Q_1(s_t, a_t), Q_2(s_t, a_t)$ – оценки действия агента по двум Q-функциям.

То есть модель старается максимизировать значение Q-функции и энтропию.

3. Value-сеть.

Для обучения Value-сети минимизируется следующая функция потерь:

$$\mathcal{L}_V(\psi) = \mathbb{E}_{s_t \sim \mathcal{D}} \left[\left(V_\psi(s_t) - \mathbb{E}_{a_t \sim \pi} [\min(Q_1(s_t, a_t), Q_2(s_t, a_t)) - \alpha * \log \pi(a_t | s_t)] \right)^2 \right] \quad (2.23)$$

где:

- $\mathcal{L}_V(\psi)$ – функция потерь Value-сети;
- s_t – состояние среды в момент времени t ;
- a_t – действие, совершенное агентом в момент времени t ;
- $\mathcal{D}$ - Replay buffer (буфер опыта), который хранит N предыдущих состояний четверки (s_t, a_t, r_t, s_{t+1}) ;
- $Q_1(s_t, a_t), Q_2(s_t, a_t)$ – оценки действия агента по двум Q-сетям;
- $\pi(a_t|s_t)$ – вероятностная политика, из которой сэмпляются действия;
- $\alpha > 0$ – коэффициент энтропийной регуляризации;
- $V_\psi(s_t)$ – предсказанное Value-сетью значение.

Обновление Target-сети происходит по формуле:

$$\psi_{target} \leftarrow \tau * \psi + (1 - \tau) * \psi_{target} \quad (2.24)$$

Где:

- ψ – текущие параметры Value-сети;
- ψ_{target} – параметры Target-сети;
- τ – коэффициент soft-обновления (нужен, чтобы обновление было медленным и стабильным).

4. Баланс между исследованием и эксплуатацией (автоматическое обновление температуры α).

$$\mathcal{L}_\alpha = \mathbb{E}_\alpha[-\alpha * (\log \pi(a_t|s_t) + \kappa_{target})] \quad (2.25)$$

Где:

- $\mathcal{L}_\alpha$ – функция потерь для параметра температуры;
- s_t – состояние среды в момент времени t ;
- a_t – действие, совершенное агентом в момент времени t ;
- $\pi(a_t|s_t)$ – вероятностная политика, из которой сэмпляются действия;
- κ_{target} – заданный целевой уровень энтропии.

2.1.5 Модель MBPO: обоснование выбора и архитектура

В отличие от предыдущих алгоритмов MBPO (Model-Based Policy Optimization) является model-based алгоритмом, что добавляет разнообразия и более полный охват характеристик моделей обучения с подкреплением в данное исследование. MBPO сочетает преимущества модельно-ориентированных и модельно-свободных методов обучения с подкреплением. Используя модель среды для генерации дополнительных данных, MBPO значительно повышает эффективность обучения, что может оказаться эффективным для решения задач маркет-мейкинга. В отличие от традиционных модельно-ориентированных методов, MBPO ограничивает количество шагов, предсказанных моделью, что снижает накопление ошибок и повышает стабильность обучения. Используемая в этом исследовании архитектура встречалась, в частности, в работе Haider [16].

Далее подробно рассмотрим полную архитектуру MBPO модели.

Пространство состояний среды и агента.

В MBPO модели предлагается использовать пространство признаков среды и агента аналогичное модели SAC, но с большим значением некоторых параметров. Предлагаемое пространство состояния $s_t \in \mathbb{R}^n$, где:

- $spread_t$ — нормированный спред (см. формулу 2.1);
- $price_level_dist_t^{bid,i}, price_level_dist_t^{ask,i}$ — расстояния от i -го уровня ask/bid до средней цены (см. формулу 2.2), где $i = \{1, 2, \dots, 10\}$;
- $notional_t^{bid,i}, notional_t^{ask,i}$ — совокупная условная стоимость на первом уровне стакана (см. формулы 2.3, 2.4), где $i = \{1, 2, \dots, 10\}$;
- OFl_t — order flow imbalance, то есть показатель изменения в спросе и предложении на актив (см. формулу 2.5);
- RSI_t^{1min} — масштабированный RSI для временного окна в 1 минуту, 3 минуты, 10 минут (см. формулу 2.6);
- $inventory_t \in [-1; 1]$ — текущий инвентарь агента (позиция) (см. формулу 2.10);

- m_window_t — скользящее окно размера 5, 10, 50, 100 для средней рыночной цены.

Пространство действий.

Пространство действий аналогично предыдущим моделям (за исключением SAC).

Функция награды.

Аналогично предыдущим моделям (см. формулу 2.11).

Архитектура нейронной сети.

Общий модельный ландшафт подхода MBPO включает в себя 3 основных компонента:

1. Модель среды $\hat{f}_\theta$.

Предсказывает переход среды:

$$\widehat{s_{t+1}}, r_t = \hat{f}_\theta(s_t, a_t)$$

где:

- $\hat{f}_\theta$ — нейросеть, обучающаяся предсказывать следующие состояние и награду.

Обучение модели идет с помощью функции MSE:

$$\mathcal{L}_\theta = \mathbb{E}[(\hat{s}_{t+1} - s_{t+1})^2 + (\hat{r}_{t+1} - r_{t+1})^2]$$

где:

- s_{t+1} — реальное значение следующего состояния;
- r_{t+1} — реальное значение следующей награды;
- $\hat{s}_{t+1}$ — предсказанное моделью следующее состояние;
- $\hat{r}_{t+1}$ — предсказанная моделью следующая награда.

Архитектура этого компонента ($\hat{f}_\theta$) представлена на Рис. 2.4.




Рис. 2.4. Архитектура модели среды для MBPO.

2. Генерация виртуальных траекторий.

Используя модель среды $\hat{f}_\theta$, сэмплируются состояния s_t из реальных данных. Генерируются виртуальные переходы длиной N шагов (чаще $N = 1-5$) по политике π_ϕ . Полученные виртуальные векторы состояний, действий и наград записываются в буфер сгенерированных состояний $\mathcal{D}_{model}$.

3. Обучение политики и Q-функции.

Обучение на батчах из $\mathcal{D}_{model}$ с помощью функций, аналогичных прошлым моделям (формула 2.14).

Алгоритм DDPG [22] не был включен в перечень используемых моделей, так как оказался крайне чувствительным к гиперпараметрам и начальным условиям, что не позволило корректно сравнивать данный алгоритм с другими, представленным в этой работе.

2.1.6 Сравнительная таблица используемых алгоритмов

В таблице 2.2 приведена информация для сравнения используемых алгоритмов с описанием основных характеристик и кратким обоснованием выбора.

Таблица 2.2 – Описание RL-алгоритмов и их основные характеристики

Алгоритм	Тип RL	Пространство действий	Сложность алгоритма	Обоснование выбора
Q-Learning	Value-based	Дискретное	Низкая	Базовый табличный метод, хорош как отправная точка и контрольная модель.
DQN (Deep Q-Network)	Value-based	Дискретное	Средняя	Представляет более мощный value-based подход с нейросетью. Уместен для обучения на рыночных состояниях.
PPO (Proximal Policy Optimization)	Policy-based	Дискретное	Средняя	Современный, устойчивый метод, широко применяется в торговых стратегиях. Один из самых популярных RL-алгоритмов.
SAC (Soft Actor-Critic)	Actor-Critic	Непрерывное	Высокая	Лучше всего справляется с непрерывной подачей цен, обеспечивает баланс между исследованием и эксплуатацией.

MBPO (Model-Based Policy Optimization)	Model-based	Дискретное	Высокая	Позволяет исследовать, как моделирование среды может повысить sample efficiency и скорость обучения.
---	-------------	------------	---------	--

2.2 Реализация симулятора торговли на бирже

Для оценки эффективности алгоритмов маркет-мейкинга необходимо использовать симулятор торговли, максимально приближенный к реальным условиям биржевой торговли. Симулятор, используемый в данном исследовании, базируется на симуляторе, реализованном для HFT на рынке криптовалют в одной из работ [13]. Особенностью этого симулятора является использование реалистичных, но при этом несложно реализуемых предпосылок. Важнейшим фактором, который нужно учесть в симуляторе, являются задержки (latency), возникающие при получении рыночных данных от биржи и отправке заявок обратно на биржу.

Симулятор должен учитывать две основные задержки:

- Задержку получения данных от биржи;
- Задержку отправки заявок на биржу.

Эти задержки обусловлены физическим расположением серверов, методом доступа к бирже, сложностью торговых алгоритмов и техническими особенностями торговых систем.

Разработанный торговый симулятор содержит в себе три основные компоненты:

1. market_data – предварительно обработанные рыночные данные;
2. md_latency – задержка поступления рыночной информации;
3. execution_latency – задержка отправки заявок на биржу.

По умолчанию задержки выставлены на уровне 10 миллисекунд, что соответствует типичным значениям в индустрии.

Симулятор включает следующие методы:

- `place_order` – размещение лимитной заявки;
- `cancel_order` – отмена текущей заявки;
- `tick` – симуляция одного тика, включающая обновление рыночных данных и обработку заявок через методы `execute_orders` и `prepare_orders`;
- `prepare_orders` – перемещение заявок, выдержавших задержку, из статуса ожидания на биржу;
- `execute_orders` – проверка исполнения заявок по новым рыночным данным.

Важной частью симулятора является поддержка Post-Only заявок, которые автоматически отменяются, если при их выставлении возникает вероятность немедленного исполнения. Это позволяет маркет-мейкеру избежать нежелательного исполнения ордеров, что способствует корректной оценке стратегий маркет-мейкинга и отражает реальные условия работы на финансовых рынках.

2.3 Сегментация данных

В качестве различных сегментов рынка для проведения исследования были выбраны следующие ценные бумаги:

1. Облигация федерального займа (SU26238RMFS4)².
2. Облигация федерального займа (SU26240RMFS0)³.
3. Акции компании Яндекс (YNDX)⁴.

ОФЗ являются наименее волатильным активом с достаточно большим объемом торгов, что упрощает работу с этими активами для RL-моделей. Кроме того, датасеты для этих сегментов содержат наблюдения, охватывающие временной период почти в 2 месяца, что потенциально поможет отразить способность модели улавливать более длительные тренды с различным объемом информации. Облигации, входящие в первый сегмент

² <https://www.moex.com/ru/issue.aspx?board=TQOB&code=SU26238RMFS4>

³ <https://www.moex.com/ru/issue.aspx?board=TQOB&code=SU26240RMFS0>

⁴ <https://www.moex.com/ru/issue.aspx?board=TQBR&code=YNDX>

более ликвидны (количество сделок с ними выше в 4-5 раз по сравнению с ОФЗ из второго сегмента), а значит модели получают больше информации о каждом конкретном снимке стакана и поведении агентов. Такие облигации являются отличным базовым рынком для тестирования стратегий на стабильность и аккуратность работы.

Во втором сегменте модель, наоборот, вынуждена справляться с неполнотой и пропусками в данных. При этом на поведение агентов с этим финансовым активом меньше всего влияния оказывает шум, а цены – самые устойчивые из всех сегментов. Здесь могут хорошо себя показать модели, которые недооценивают краткосрочные изменения на финансовом рынке, а улавливают более долгосрочные тренды.

Акции компании Яндекс в данном исследовании будут рассматриваться за временной период в 1 день работы биржи. Количество сделок по этому активу позволяет рассматривать способность работы модели на более коротком временном промежутке и обучаться под внутридневные зависимости и особенности торгов, например, спрос со стороны розничных трейдеров. Тестирование моделей на этом сегменте позволяет оценить качество реактивности моделей, способности быстро адаптироваться к новым рыночным условиям. Однако высокая зашумленность данных может мешать более спокойным RL-алгоритмам показывать высокие результаты.

Глава 3. Результаты исследования

3.1 Описание данных

Массивы данных состоят из снимков книги лимитных заявок с несколькими первыми уровнями стакана, собранными на каждый «тик». Количество уровней, подаваемых на вход каждой модели, соответствует количеству, описанному в Главе 2. «Тик» – обновление данных каждый раз, когда в книге лимитных заявок происходит обновление на интересующих нас уровнях стакана:

- новая заявка попадает в стакан;
- заявка из стакана снимается с торгов;
- происходит сделка по заявке в стакане.

Массивы данных по высоколиквидным ОФЗ состоят из 1.8 млн строк (34 торговых дня), для низколиквидных – 1.2 млн строк (34 торговых дня), для корпоративных акций компании Яндекс – из 11 миллионов строк (2 торговых дня). Данные для тестирования брались за последние временные промежутки, представленные в данных, с помощью подхода Out-Of-Time (ООТ). Для сегментов 1 и 2 в качестве тестовой выборки были выбраны снимки стаканов за 3 торговых дня: с 19.03.2024 по 21.03.2024. Для сегмента 3 в качестве тестовой выборки брались наблюдения за последние 6 часов торгов: с 18:00:00 02.02.2024 по 23:59:59 02.02.2024. Валидационные выборки, которые использовались в процессе отладки моделей выделялись из выборок для обучения с помощью подхода ООТ: 17.03.2024-18.03.2024 для сегментов 1 и 2; 16:00:00 02.02.2024-17:59:59 02.02.2024 для сегмента 3.

Основная информация о датасетах, использованных в работе, представлена в таблице 3.1. Более подробная информация и статистика приведена в Приложении 1.

Таблица 3.1 – Основная информация о выборках

Сегмент	Тип выборки	Кол-во тиков	Дата и время начала торгов	Дата и время завершения торгов
1	train	1,488,331	01.02.2024 10:00	16.03.2024 23:59
	val	187,841	17.03.2024 10:00	18.03.2024 23:59
	test	328,440	19.03.2024 10:00	21.03.2024 23:59
2	train	963,629	01.02.2024 10:00	16.03.2024 23:59
	val	114,252	17.03.2024 10:00	18.03.2024 23:59
	test	166,145	19.03.2024 10:00	21.03.2024 23:59
3	train	10,330,423	01.02.2024 10:00	02.02.2024 17:59
	val	700,993	02.02.2024 16:00	02.02.2024 17:59
	test	109,785	02.02.2024 18:00	02.02.2024 23:59

3.2 Результаты моделей в сегменте высоколиквидных ОФЗ

Итоговые результаты работы моделей в сегменте высоколиквидных ОФЗ представлены в таблице 3.2.

Таблица 3.2 – Результаты применения моделей в сегменте 1

Модель	Итоговая прибыль (Р)	Пассивная прибыль (Р)	Чистая прибыль (Р)	Общий поставленный объём
Q-Learning	1900	4480	-2580	1700
DQN	4700	4480	220	6200
PPO	3900	4480	-580	4300
SAC	6800	4480	2320	10400
MBPO	4900	4480	420	200

Период тестирования моделей составил три торговых дня с 19.03.2024 по 21.03.2024. За этот период стоимость облигаций увеличилась с 59,998 рублей до 60,446 рублей за облигацию. Пассивное удержание изначально имевшихся в портфеле у каждой из моделей 10 000 облигаций принесло бы прибыль в размере примерно 4480 рублей, что является важным ориентиром для оценки реальной эффективности стратегий.

Модель Q-Learning показала итоговую прибыль в размере 1900 рублей. Однако с учетом того, что пассивная стратегия без торговли обеспечила бы прибыль 4480 рублей, результат Q-Learning оказывается отрицательным при сравнении с buy-and-hold стратегией. Более того, низкий суммарный объём выставленных заявок (всего 1700 облигаций) показывает, что модель вела себя слишком консервативно и недостаточно активно выполняла основную функцию маркет-мейкера — обеспечение ликвидности рынка. В условиях высокой ликвидности и большого объема данных можно было ожидать, что табличная модель будет обучена достаточно хорошо. Однако низкая прибыль указывает на ограниченную способность Q-Learning обобщать сложные зависимости между признаками и действиями. Основная проблема здесь — дискретизация пространства состояний. Табличная модель требует, чтобы каждое уникальное состояние было явно представлено в таблице. При небольшом количестве признаков количество возможных состояний не так велико, что могло положительно сказаться на модели. Однако большое количество уникальных значений из признакового пространства привело к тому, большинство состояний в таблице Q остаются плохо исследованными или вовсе не покрытыми. В результате модель может "заучить" поведение для часто встречающихся паттернов, но не умеет адаптироваться к новым ситуациям. Это также объясняет низкую торговую активность: модель боится делать что-то неизвестное, чтобы не попасть в плохо изученное состояние. А учитывая общий тренд на постепенное повышение цены актива, таких неизвестных ситуаций оказалось довольно много.

Модель DQN достигла лучшего результата с итоговой прибылью в 4700 рублей. Это превышает прибыль от простого удержания облигаций примерно на 220 рублей, что является положительным, хотя и незначительным преимуществом. Объём заявок составил 6200 облигаций, что говорит о заметной активности модели и её способности использовать возможности рынка. Однако итоговая сверхприбыль, превышающая buy-and-hold результат, остается достаточно скромной, и эффективность DQN можно

охарактеризовать как умеренную. В целом на этом сегменте DQN продемонстрировал уверенный результат: как по объему размещенной ликвидности, так и по прибыли, которая оказалась выше, чем у некоторых конкурентов. Это стало возможным благодаря способности DQN использовать признаки стакана (ценовые уровни, спред, notional, OFI, RSI и др.) в полном объеме и обобщать паттерны в поведении рынка. В отличие от Q-Learning, модель могла не просто запоминать состояния, а учиться их понимать через нелинейные преобразования в нейросети. Высокая ликвидность и большая глубина рынка создают много частых ситуаций, в которых DQN может устойчиво обучаться. Replay buffer позволил сохранять разнообразие эпизодов, а обучение в мини-батчах — избегать переобучения на локальных паттернах. В итоге, DQN смог сформировать одну из самых активных маркет-мейкер стратегий: он часто вставал в стакан с двух сторон и зарабатывал на небольших рыночных движениях.

Модель PPO продемонстрировала прибыль в размере 3900 рублей, что является отрицательным результатом в сравнении с пассивной стратегией. Прибыль PPO на 580 рублей ниже, чем прибыль простого удержания актива. Общий поставленный объём в 4300 облигаций говорит о средней активности модели. Таким образом, PPO, хотя и продемонстрировала умеренную торговую активность, не смогла эффективно извлечь выгоду из колебаний рынка, проиграв buy-and-hold подходу и некоторым другим моделям. Его прибыль оказалась выше, чем у табличного Q-Learning, но ниже, чем у DQN, SAC и MBPO. Важно понимать, что PPO ориентирован на обучение политики, а не Q-функции, и его поведение более «гладкое» и стабилизированное. Это проявилось и здесь: стратегия PPO не была сверхагрессивной, но выработала сбалансированную модель поведения: заявки на глубине 1–3 уровней, умеренные объемы, избегание необоснованных рыночных рисков. При этом PPO был не так чувствителен к локальной рыночной структуре, как, например, SAC, и, возможно, из-за этого не смог в полной мере использовать все возможности по арбитражу или

быстрой адаптации к изменению спреда. В высоколиквидной среде, где условия быстро меняются, но при этом данных для обучения не так много (как, например, в сегменте 3), это показало себя недостатком.

Модель SAC оказалась наиболее эффективной среди всех протестированных на данном сегменте. Итоговая прибыль составила 6800 рублей, что на 2320 рублей превосходит прибыль пассивной стратегии удержания облигаций. Это значительный и очень позитивный результат, особенно с учетом того, что модель выставила заявки на общий объём 10400 облигаций, максимально активно используя возможности высоколиквидного рынка и узкие спреды между ценами покупки и продажи. Высокая прибыль и значительный объём торгов подтверждают, что SAC эффективно выполняла именно задачи маркет-мейкинга. Высоколиквидный рынок с узким спредом и постоянным потоком сделок проявил себя в качестве идеальной среды для этого алгоритма. Он может извлекать выгоду из большого количества торговых возможностей, не повторяя одну и ту же стратегию, а динамически адаптируя поведение к рыночной ситуации. Высокая энтропия политики позволила SAC не застревать в локальных паттернах поведения, как это бывает у DQN, и не бояться рискнуть, если сигнал был сильным. SAC выставял много ордеров, занимал агрессивные уровни в стакане и успевал их корректировать — всё благодаря высокой скорости и стабильности обучения.

Модель MBPO получила итоговую прибыль 4900 рублей, что на 420 рублей превышает прибыль пассивной стратегии. На первый взгляд результат кажется положительным, однако крайне низкая торговая активность (всего 200 облигаций за весь период) ставит под вопрос её эффективность именно в роли маркет-мейкера. В реальных рыночных условиях столь малое количество сделок говорит о том, что модель практически не предоставляла ликвидности, хотя и смогла точно получить небольшую сверхприбыль. Более того, MBPO продемонстрировала очень высокую эффективность на сделку. Алгоритм обучается на предсказаниях

модели и старается действовать только в условиях высокой уверенности. В данном случае MBPO реже входил в рынок, ждал моментов с высокой вероятностью положительного исхода (по предсказаниям своей модели) и получал прибыль за счёт осторожности и точности, а не масштабыности. Однако такой подход не является эффективным решением для задачи маркет-мейкера.

Таким образом, по итогам исследования сегмента высоколиквидных облигаций федерального займа наиболее эффективной стратегией оказалась модель SAC, которая не только продемонстрировала существенную прибыль, значительно превышающую пассивную стратегию удержания облигаций, но и активно выполняла задачу маркет-мейкера. Модель DQN и MBPO показали умеренно позитивные результаты, однако каждая с заметными недостатками: DQN лишь незначительно превзошла buy-and-hold стратегию, а MBPO была чрезвычайно пассивной. Модели Q-Learning и PPO оказались неэффективны, так как их результаты не достигли прибыли от пассивного владения активами. В итоге, для данного сегмента рекомендовано использование модели SAC, как наиболее подходящей для высоколиквидного рынка.

3.3 Результаты моделей в сегменте низколиквидных ОФЗ

Итоговые результаты работы моделей в сегменте низколиквидных ОФЗ представлены в таблице 3.3.

Таблица 3.3 – Результаты применения моделей в сегменте 2

Модель	Итоговая прибыль (₽)	Пассивный прибыль (₽)	Чистая прибыль (₽)	Общий поставленный объём
Q-Learning	10	-940	950	200
DQN	200	-940	1140	700
PPO	2100	-940	3040	3800
SAC	800	-940	1740	1400
MBPO	-100	-940	840	2000

Анализ работы моделей проводился за тот же трёхдневный период с 19.03.2024 по 21.03.2024. За указанный период стоимость актива незначительно снизилась с 64,499 до 64,405 рублей, что соответствует убытку около 940 рублей при пассивном удержании 10 000 облигаций без совершения сделок.

Модель Q-Learning на этом сегменте показала итоговую прибыль в размере всего 10 рублей. Несмотря на формально положительный результат, это крайне низкий показатель прибыли, особенно учитывая, что за счёт изменения цены актива без торговых операций получился бы убыток в 940 рублей. С учетом этой переоценки, чистый результат модели Q-Learning можно интерпретировать как небольшую компенсацию этого убытка, то есть модель достаточно надежно показала себя в качестве базовой стратегии. Однако минимальный общий поставленный объём в 200 облигаций демонстрирует, что модель была практически неактивна и не смогла эффективно выступить в роли маркет-мейкера. Это ожидаемо: модель опять же стремится избегать действий в условиях неопределенности. А в сегменте, где сделки происходят редко и рынок описывается большим количеством пропущенных данных, таких ситуаций очень много. Сама структура Q-Learning делает её очень чувствительной к недостатку обратной связи. Когда агент совершает действие, но оно редко приводит к значимой награде (например, сделка не исполняется), обучение становится крайне медленным. Для маркет-мейкинга на низколиквидных активах важно уметь оперировать с отложенными наградами и оценивать вероятности исполнения заявок, чего Q-Learning не делает.

Модель DQN показала несколько более высокий результат, достигнув итоговой прибыли в 200 рублей. Чистая прибыль модели составляет примерно 1 140 рублей, что лучше, чем результат Q-Learning, но также является умеренно низким показателем. Активность модели оставалась низкой (объём сделок составил всего 700 облигаций). Это связано с тем, что на таких рынках у агента редко бывает обратная связь (исполнение сделок

происходит нечасто), а шум и "пустые" состояния преобладают. Тем не менее, благодаря обучению на батчах и обобщающим способностям нейросети, DQN смог научиться избегать убыточных действий (например, выставления ордеров в слишком рискованных точках) и формировать стратегию, ориентированную на редкие, но надежные сделки. Его преимущество перед табличной моделью — именно в том, что он может экстраполировать знания на редко встречающиеся состояния, если они похожи на известные. Это и позволило ему хоть что-то заработать в условиях низкой плотности данных.

Модель PPO оказалась наиболее эффективной стратегией во втором сегменте, продемонстрировав итоговую прибыль в размере 2100 рублей. Учитывая, что пассивное удержание актива принесло бы убыток в 940 рублей, чистая прибыль PPO составила 3040 рублей. Это весьма заметный и убедительный результат для условий низкой ликвидности. Более того, модель PPO активно выставляла заявки, общий поставленный объём составил 3800 облигаций, что подтверждает её хорошую способность адаптироваться к низкой частоте сделок и использовать широкие спреды для извлечения прибыли. В этом сегменте PPO показывает себя лучше всех из-за policy-based природы. В отличие от DQN, который учится на дискретных переходах и страдает при недостатке обратной связи, PPO способен обобщать стратегическое поведение, даже если положительных примеров немного. Алгоритм смог найти сбалансированный подход к размещению ордеров и не пытался резко менять стратегию, если среда не предоставляла нового сигнала, что позволило ему избегать убытков от лишней активности, сохраняя при этом высокую эффективность. Этот результат показывает силу PPO в условиях, где важна долгосрочная устойчивость и гибкость, а не максимизация мгновенной выгоды.

Модель SAC в низколиквидных условиях продемонстрировала умеренный результат, достигнув итоговой прибыли 800 рублей. Чистая прибыль с учётом пассивного убытка составила 1740 рублей, что является

положительным, но далеко не лидирующим результатом. SAC была умеренно активной (1400 облигаций в общем поставленном объёме), но не смогла в полной мере использовать потенциал спредов и редких сделок. Хотя модель и оказалась эффективнее простых подходов (Q-Learning, DQN), она значительно уступила PPO, показывая среднюю адаптивность к сложным условиям низколиквидного рынка. В малоликвидной среде агрессивность SAC оказалась не столь оправданной. Элементы стохастичности в его политике, которые отлично работают на активном рынке, здесь приводили к частым размещениям ордеров, которые не приносили результата. При этом важно отметить: SAC смог обойти Q-Learning и DQN, что подтверждает его способность находить обобщённые и адаптивные стратегии даже в сложных условиях. Он не оказался в убытке, как MBPO, потому что сохранял умеренную активность и не переобучался на редкие успешные эпизоды.

Модель MBPO на этом сегменте была единственной моделью с отрицательным итоговым результатом: её прибыль составила минус 100 рублей. С учетом снижения стоимости облигаций и пассивного убытка 940 рублей, реальная эффективность модели MBPO выражается в том, что она частично компенсировала этот убыток (итоговая чистая прибыль 840 рублей относительно пассивного удержания). Несмотря на относительно высокий общий объём торговых операций (2000 облигаций), модель не смогла качественно прогнозировать изменения цен и, видимо, ошибочно размещала заявки, не получая положительной маржи в результате маркет-мейкинга. Это ставит под сомнение её эффективность в данных условиях и требует дополнительной настройки и улучшения её прогностической модели. Вероятная причина — некачественное приближение среды: модель динамики рынка на низколиквидных ОФЗ оказывается неустойчивой. Модель переоценивает вероятность исполнения ордеров или неправильно предсказывает изменение цены, в результате чего: генерация обучающих смоделированных переходов искажена, следовательно, алгоритм обучается на ложных представлениях, а действия, основанные на этой стратегии, в

реальной среде приводят к потере денег. MBPO активно торговал (2000 контрактов) — это как раз подтверждает, что модель обучилась на некорректном чувстве уверенности при совершении сделок, а в реальности сделки не были прибыльными. Здесь и проявился типичный риск для model-based RL, а именно высокая чувствительность к ошибкам модели среды.

Таким образом, наиболее эффективной моделью на сегменте низколиквидных облигаций федерального займа стала модель PPO, которая успешно справилась с задачей активного маркет-мейкинга, показала существенную чистую прибыль и высокий уровень торговой активности. Модели SAC и DQN показали умеренные результаты, которые, хотя и позитивны, всё же значительно уступают PPO. Модели Q-Learning и MBPO оказались наименее эффективны: Q-Learning – из-за практически полного отсутствия активности, MBPO – из-за неспособности корректно прогнозировать и извлекать прибыль из торговли. Для данного сегмента, таким образом, наиболее рекомендуемой стратегией является PPO, способная стабильно и эффективно предоставлять ликвидность в условиях низкой активности рынка.

3.4 Результаты моделей в сегменте акций

Итоговые результаты работы моделей в сегменте высоколиквидных акций представлены в таблице 3.4.

Таблица 3.4 – Результаты применения моделей в сегменте 3

Модель	Итоговая прибыль (₽)	Пассивная прибыль (₽)	Чистая прибыль (₽)	Общий поставленный объём
Q-Learning	40200	39600	600	800
DQN	43800	39600	4200	1600
PPO	37900	39600	-1700	1900
SAC	41200	39600	1600	700
MBPO	45000	39600	5400	2400

Тестирование моделей проходило на интервале в 4 часа торгов (с 20:00 до 23:59 02.02.2024). За данный период цена акции выросла с 3123,4 рублей до 3163 рублей. При пассивном удержании изначально имевшихся 1000 акций без совершения сделок прибыль составила бы примерно 39600 рублей.

Модель Q-Learning за указанный период достигла итоговой прибыли 40200 рублей. Прибыль превосходит результат buy-and-hold стратегии на 600 рублей, что является минимальным превышением из всех моделей. С точки зрения активности, модель проявила себя крайне консервативно, поставив на рынок заявки лишь на 800 акций, но это выше чем результат модели в сегменте 2. Такой низкий уровень активности указывает на то, что модель была неэффективна в роли активного маркет-мейкера, хотя и смогла получить незначительную прибыль сверх пассивного удержания. В целом, Q-Learning в этом сегменте оправдала ожидания по интенсивности торговли и предоставлению ликвидности, так как в качестве базовой стратегии получилось показать положительный результат. Можно оценить этот сегмент самым благоприятным для Q-Learning. Во-первых, большой объем данных обеспечил достаточное покрытие таблицы состояний. Во-вторых, высокая волатильность создает больше возможностей для получения прибыли, даже при минимальном участии. В этом случае агент мог успешно "подстроиться" под частые паттерны рынка и использовать знакомые ситуации для безопасных сделок. Однако стоит отметить, что даже здесь Q-Learning обошёл пассивное владение активом всего на 600 рублей. Это указывает на то, что вся прибыль была получена скорее "вопреки", чем благодаря возможностям алгоритма. Табличная модель не может оценить динамику или неопределенность. Она действует по памяти, а не по оценке. Поэтому активные стратегии с большим объемом сделок ей труднодоступны.

Модель DQN показала итоговую прибыль 43800 рублей, что на 4200 рублей превышает прибыль от простой buy-and-hold стратегии. Это позитивный и значимый результат, демонстрирующий, что модель DQN смогла успешно использовать краткосрочные колебания цены акций для

получения прибыли. Общий объём торговых операций составил 1600 акций, что указывает на умеренную активность модели. DQN оказалась эффективной в плане реализации стратегии маркет-мейкинга, хотя уровень активности мог бы быть выше для максимизации прибыли в условиях волатильного рынка. DQN достаточно активно использовал широкое пространство признаков и выработал стратегию, адаптирующуюся под краткосрочные изменения. При этом она избегала резких движений и не попадала в большие убытки благодаря регулярному обучению и обновлению целевой сети. Важно отметить, что DQN обошёл Q-Learning на фоне растущей цены актива, то есть очевидно, что его прибыль была не только за счёт пассивного роста портфеля, но и за счёт активного участия в торгах.

Модель PPO получила итоговую прибыль в размере 37900 рублей, что ниже, чем прибыль простого удержания актива на 1700 рублей. Это означает, что модель не только не смогла эффективно использовать преимущества волатильности рынка, но и понесла убыток относительно buy-and-hold стратегии. С точки зрения активности модель была достаточно активной, выставив заявки на 1900 акций, однако высокая активность не смогла компенсировать неудачные решения по размещению заявок. В результате модель PPO проявила себя неэффективно в сегменте с высокой волатильностью и высокой ликвидностью, в отличие от сегмента 2. За счёт своей устойчивости модель PPO, вероятно, не успела подстроиться под активность в краткосрочном периоде.

Модель SAC достигла итоговой прибыли в размере 41200 рублей. Этот результат превышает прибыль от пассивного удержания на 1600 рублей. Хотя это положительный результат, его нельзя назвать значительным. К тому же общая торговая активность модели была очень низкой: всего 700 акций были задействованы в торговых операциях. Это указывает на консервативную стратегию модели, которая предпочитала минимально рисковать. В итоге модель SAC показала приемлемую прибыльность, но оказалась менее эффективной в плане активности и предоставления

ликвидности рынку, уступая более успешным моделям. Политика с максимизацией энтропии в высоковолатильной среде не дала SAC преимущество: вероятно, за счет короткого периода тестирования модели, в эти часы торгов не случилось множества рыночных ситуаций, на которых модель обучалась, и заняла более выжидающую стратегию.

Наиболее эффективной моделью для данного сегмента оказалась модель MBPO, которая смогла добиться итоговой прибыли в 45000 рублей, что превосходит прибыль пассивного удержания актива на 5400 рублей. Это наилучший показатель среди всех исследованных моделей, демонстрирующий высокую точность принятия решений и успешное использование краткосрочных волатильных движений рынка. Кроме того, MBPO активно размещала заявки, общий поставленный объем составил 2400 акций, что является самым высоким среди всех моделей. Это подтверждает, что модель эффективно выполняла задачу маркет-мейкера, предоставляя значительную ликвидность и получая дополнительную прибыль именно от активности и частых сделок. Причины такого успеха алгоритма кроются в избегании ошибок, сделанных в низколиквидном сегменте:

- Объем обучающих данных (6 млн тиков) был очень велик, что дало MBPO возможность построить надёжную модель среды.
- Высокая волатильность и частота сделок — идеальные условия для планирования на несколько шагов вперёд.
- MBPO смог найти высокомаржинальные паттерны и научился срабатывать на «предугадываемом» поведении рынка.

Таким образом, в условиях, где рынок предсказуем и хорошо покрыт данными, MBPO становится лидером. В отличие от SAC, он не нуждается в большой энтропии — ему важна стабильность и точность модели.

Итоговым результатом по третьему сегменту (акции высокотехнологичной компании) стало следующее: модель MBPO является однозначным лидером по эффективности, активно и успешно используя высокую волатильность и умеренную ликвидность рынка для получения

прибыли, превышающей пассивную buy-and-hold стратегию. Модель DQN также показала хорошие результаты и может быть рассмотрена как достойная альтернатива, хотя и с несколько меньшей активностью. SAC обеспечила умеренную эффективность, но слишком низкая активность ограничивает её использование. Модели Q-Learning и PPO не оправдали ожиданий, показав либо низкую прибыльность, либо убытки относительно пассивного владения активами, и поэтому не рекомендованы для работы в данном сегменте.

Заключение

В ходе сравнительного анализа пяти алгоритмов обучения с подкреплением с различными характеристиками и особенностями работы — Q-Learning, DQN, PPO, SAC и MBPO — применительно к задаче маркет-мейкинга на трёх различных сегментах финансового рынка, которые различались как качеством и размером обучающих выборок, так и особенностями поведения агентов на этих рынках, были выявлены отчетливые различия в эффективности RL-подходов, объясняемые как математической природой моделей, так и спецификой рассматриваемых рыночных условий.

Алгоритм Q-Learning, основанный на табличной аппроксимации Q-функции, продемонстрировал крайне ограниченные возможности в условиях реального рынка. В основе Q-Learning лежит предположение, что все состояния среды можно эффективно дискретизировать и сохранить в таблице, что делает его чувствительным к размерности и разнообразию пространства признаков. Обучение этой модели шло на ограниченном пространстве признаков, что не позволило модели поймать сложные рыночные зависимости. Во всех сегментах модель показала либо недостаточную торговую активность, либо неспособность адаптироваться к изменяющимся рыночным условиям. Несмотря на то, что в третьем сегменте — на высокочастотных данных с большим объемом и волатильностью — Q-Learning смог превзойти пассивную стратегию buy-and-hold, его отрыв был минимальным и скорее случайным. Общая проблема этой модели — отсутствие обобщающей способности: она не умеет интерпретировать незнакомые ситуации и, как следствие, не способна формировать устойчивую стратегию в условиях высокой динамичности рынка. Особенно плохо она показала себя на рынках с низкой ликвидностью, где даже малейшая неопределенность приводит к отказу от действий.

Модель DQN, являющаяся нейросетевым расширением Q-Learning, способна решать проблемы своего предшественника благодаря своей способности к аппроксимации сложных и непрерывных Q-функций. Опора на replay-buffer и использование целевой сети позволили стабилизировать обучение и избежать переобучения на локальные паттерны. DQN показал сбалансированную торговую стратегию на всех сегментах. В первом сегменте он заработал чуть больше, чем стратегия buy-and-hold, демонстрируя умеренную активность и положительную прибыль. В третьем сегменте, обладая богатым обучающим датасетом и высокой рыночной волатильностью, DQN смог существенно превзойти пассивную стратегию, получив значимую чистую прибыль. Однако на низколиквидном рынке он, несмотря на положительный результат, продемонстрировал ограниченную активность, что указывает на сложности в обучении при недостаточной частоте обратной связи. В целом, DQN можно охарактеризовать как надёжную модель с умеренной агрессивностью, способную адаптироваться к различным рыночным условиям, особенно если данные обильны и разнообразны.

PPO, как представитель policy-based подходов, фокусируется не на обучении Q-функции, а на непосредственной оптимизации стратегии. Благодаря этому алгоритм менее зависим от точного предсказания награды за каждое действие и больше ориентирован на глобальные закономерности поведения. В сегменте низколиквидных ОФЗ PPO стал абсолютным лидером, продемонстрировав не только высокую прибыль, но и наибольшую торговую активность. Он оказался наиболее устойчивым к недостатку обратной связи и использовал даже редкие торговые возможности эффективно. Однако в условиях более агрессивного рынка — как в сегменте с акциями — PPO уступил конкурентам, не сумев подстроиться под быстро меняющиеся условия и потеряв деньги относительно пассивной стратегии. Это объясняется структурной особенностью PPO: он обучается в рамках ограничений (через доверительную область), что делает его устойчивым, но

менее гибким в нестабильных условиях. Его поведение в высоколиквидной среде также оказалось более консервативным, чем у DQN и SAC, что привело к худшим результатам по сравнению с конкурентами.

SAC — это модель, стремящаяся одновременно максимизировать ожидаемую награду и энтропию стратегии, то есть разнообразие возможных действий. Благодаря этому, SAC способен более гибко адаптироваться к изменению среды, избегать застревания в локальных стратегиях и эффективно исследовать пространство действий. Именно эта особенность помогла ему добиться наилучших результатов на высоколиквидном рынке облигаций с несколько ограниченным датасетом, где постоянное присутствие в стакане и способность быстро реагировать на рыночные колебания особенно важны. SAC показал высокую активность и значимую чистую прибыль, превзойдя все модели в первом сегменте. В условиях низкой ликвидности он продемонстрировал умеренные, но положительные результаты, избежав переобучения или неоправданной активности. Однако в третьем сегменте SAC оказался неожиданно пассивным, возможно, из-за краткости тестового периода или несовпадения структуры обучающих данных с реалиями тестовой среды. Тем не менее, его обобщающие способности и адаптивность, свойственная Actor-Critic моделям, делают SAC универсальным инструментом для задач, где важно равновесие между исследованием и использованием.

MBPO — единственный model-based алгоритм, представленный в данном исследовании. Он использует модель среды, а не напрямую обучается на взаимодействиях с реальной средой. Её эффективность зависит от способности правильно аппроксимировать рыночную динамику, что делает её чувствительной к качеству данных. В сегменте высоколиквидных ОФЗ MBPO проявила себя достаточно уверенно: с минимальной активностью она смогла получить небольшую, но стабильную прибыль. Это подчеркивает её консерватизм: MBPO действует только в условиях высокой уверенности. Однако в сегменте низкой ликвидности эта модель потерпела

неудачу. Неточности модели среды, ошибочные предположения о вероятности исполнения заявок и переоценка потенциальной прибыли привели к убыткам, несмотря на высокую активность. В то же время, в третьем сегменте — при наличии огромного обучающего массива и высокой предсказуемости рыночных паттернов — MBPO показала блестящий результат, став лидером как по прибыли, так и по объему торгов. Это подтверждает, что при качественном построении модели среды MBPO может успешно оперировать в самых сложных условиях, извлекая прибыль из прогнозируемых изменений.

Обобщая, можно утверждать, что выбор модели маркет-мейкера должен быть обусловлен конкретной рыночной средой. В условиях высокой ликвидности и предсказуемых паттернов наиболее эффективным является SAC, благодаря своей способности к агрессивной, но контролируемой торговле. В условиях низкой ликвидности, где важна устойчивость и осторожность, наилучшие результаты показывает PPO, способный стабильно действовать даже при редкой обратной связи. В высокочастотной, волатильной и глубокой по данным среде абсолютным лидером оказывается MBPO — модель, использующая силу аппроксимированной среды для оптимального планирования. DQN сохраняет устойчивую эффективность на всех сегментах, особенно когда данные достаточно богаты и позволяют хорошо обучить нейросетевую аппроксимацию. А вот Q-Learning, несмотря на свою методическую простоту, оказался неэффективен в реальной торговле и практически не может быть рекомендован для применения вне синтетических сред или задач с ограниченным числом состояний.

В дальнейших работах следует рассмотреть сравнение данных моделей с другими методологическими предпосылками и с другими наборами данных для выстраивания более общего понимания работы RL-подходов в задаче маркет-мейкера. Кроме того, можно углубиться в каждую из представленных моделей, чтобы узнать, каких максимальных результатов можно добиться

при оптимальном подборе архитектур, гиперпараметров и особенностях формирования обучающих датасетов.

Таким образом, исследование подтверждает необходимость гибкого и адаптивного подхода к выбору алгоритма в зависимости от рыночных условий, а также совершенно различное поведение RL-алгоритмов в разных сегментах рынка.

Список использованных источников

1. Aldridge I. High-frequency trading: a practical guide to algorithmic strategies and trading systems. – John Wiley & Sons, 2013.
2. Avellaneda M., Stoikov S. High-frequency trading in a limit order book // Quantitative Finance. 2008. Т. 8, No. 3. С. 217–224.
3. Bakshaev A. Market-making with reinforcement-learning (SAC) //arXiv preprint arXiv:2008.12275. – 2020.
4. Biais B. et al. HFT and market quality //Bankers, Markets & Investors. – 2014. – Т. 128. – №. 1. – С. 5-19.
5. Briola A. et al. Deep reinforcement learning for active high frequency trading //arXiv preprint arXiv:2101.07107. – 2021.
6. Cao Y., Liu W., Zhang X. Deep Reinforcement Learning for Trading // Applied Intelligence. 2023. URL: <https://link.springer.com/article/10.1007/s10489-023-04647-9> (дата обращения: 23.03.2025).
7. Dai W. et al. Reinforcement Learning and Deep Learning for Algorithmic Trading // Mathematics. 2021. Т. 9, No. 21. URL: <https://www.mdpi.com/2227-7390/9/21/2689> (дата обращения: 23.03.2025).
8. Dayan P., Watkins C. Q-learning //Machine learning. – 1992. – Т. 8. – №. 3. – С. 279-292.
9. Deng Y. et al. Deep Direct Reinforcement Learning for Financial Signal Representation and Trading // IEEE Transactions on Neural Networks and Learning Systems. 2017. Т. 28. С. 653–664.
10. FT.com. [Электронный ресурс]. URL: <https://www.ft.com/content/4bedfc86-df01-44d8-ae31-6d7fa37520c9> (дата обращения: 23.03.2025).
11. Gašperov B. et al. Reinforcement learning approaches to optimal market making //Mathematics. – 2021. – Т. 9. – №. 21. – С. 2689.

12. Gašperov B., Kostanjčar Z. Market making with signals through deep reinforcement learning // IEEE access. – 2021. – Т. 9. – С. 61611-61622.
13. github.com [Электронный ресурс]. URL: <https://github.com/ESkripichnikov/market-making> (дата обращения: 23.03.2025).
14. Guéant O. Optimal market making // Applied Mathematical Finance. – 2017. – Т. 24. – №. 2. – С. 112-154.
15. Haarnoja T. et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor // International conference on machine learning. – Pmlr, 2018. – С. 1861-1870.
16. Haider A. et al. Predictive market making via machine learning // Operations Research Forum. – Springer International Publishing, 2022. – Т. 3. – №. 1. – С. 1-21.
17. Ho T., Stoll H. R. Optimal dealer pricing under transactions and return uncertainty // Journal of Financial economics. – 1981. – Т. 9. – №. 1. – С. 47-73.
18. Hsieh C.-S., Wang Y.-J. Reinforcement learning-based portfolio management: a comprehensive review // Operations Research Forum. 2022. URL: <https://link.springer.com/article/10.1007/s43069-022-00124-0> (дата обращения: 23.03.2025).
19. Janner M. et al. When to trust your model: Model-based policy optimization // Advances in neural information processing systems. – 2019. – Т. 32.
20. Jones C. What Do We Know About High-Frequency Trading? [Электронный ресурс]. URL: https://safe-frankfurt.de/fileadmin/user_upload/editor_common/Events/Summer_Academy/SA2016_Jones-HFT-Survey-SSRN-id2236201-2013.pdf (дата обращения: 23.03.2025).
21. Kumar P. Deep reinforcement learning for high-frequency market making // Asian Conference on Machine Learning. – PMLR, 2023. – С. 531-546.

- 22.Lillicrap T. P. et al. Continuous control with deep reinforcement learning //arXiv preprint arXiv:1509.02971. – 2015.
- 23.Lim Y. S., Gorse D. Reinforcement learning for high-frequency market making //ESANN 2018-Proceedings, European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning. – Esann, 2018. – С. 521-526.
- 24.Lu D.W. Agent inspired trading using recurrent reinforcement learning and LSTM neural networks. arXiv preprint arXiv:1707.07338v1, 2019.
- 25.Mahajan Y. D. Optimization of MACD and RSI indicators: An empirical study of Indian equity market for profitable investment decisions //Asian Journal of Research in Banking and Finance. – 2015. – Т. 5. – №. 12. – С. 13-25.
- 26.Mnih V. et al. Human-level control through deep reinforcement learning //nature. – 2015. – Т. 518. – №. 7540. – С. 529-533.
- 27.Moody J., Wu L., Liao Y., Saffell M. Performance Functions and Reinforcement Learning for Trading Systems and Portfolios. arXiv preprint arXiv:1707.06347, 2017. URL: <https://arxiv.org/abs/1707.06347> (дата обращения: 23.03.2025).
- 28.Mosavi A. et al. Comprehensive review of deep reinforcement learning methods and applications in economics //Mathematics. – 2020. – Т. 8. – №. 10. – С. 1640.
- 29.Order Flow Imbalance. [Электронный ресурс]. URL: <https://dm13450.github.io/2022/02/02/Order-Flow-Imbalance.html> (дата обращения: 23.03.2025).
- 30.Post-Only Order [Электронный ресурс]. URL: http://www.nasdaqtrader.com/content/productsservices/trading/postonly_factsheet.pdf (дата обращения: 23.03.2025).
- 31.Sadana K., Sharma S. Reinforcement Learning for Trading // Practical Deep Learning for Cloud, Mobile, and Edge. Springer, 2020. P. 77–94. URL:

- https://link.springer.com/chapter/10.1007/978-1-4842-5127-0_4 (дата обращения: 23.03.2025).
- 32.Sadighian J. Deep reinforcement learning in cryptocurrency market making //arXiv preprint arXiv:1911.08647. – 2019.
- 33.Schulman J. et al. Proximal policy optimization algorithms //arXiv preprint arXiv:1707.06347. – 2017.
- 34.Sharpe W.F. The Sharpe ratio // Journal of Portfolio Management. 1994. Vol. 21. No. 1. P. 49–58. URL: <https://link.springer.com/article/10.1007/BF00992698> (дата обращения: 23.03.2025).
- 35.Spooner T., Savani R. Robust market making via adversarial reinforcement learning //arXiv preprint arXiv:2003.01820. – 2020..
- 36.Théate T., Ernst D. An Application of Deep Reinforcement Learning to Algorithmic Trading. arXiv preprint arXiv:2004.06627v1, 2020.
- 37.Vicente Ó. F., Fernández F., García J. Automated market maker inventory management with deep reinforcement learning //Applied Intelligence. – 2023. – Т. 53. – №. 19. – С. 22249-22266.
- 38.Zhang X., Feng J. Deep Reinforcement Learning for Trading. arXiv preprint arXiv:1906.08253, 2019. URL: <https://arxiv.org/abs/1906.08253> (дата обращения: 23.03.2025).
- 39.Zhang Z., Zohren S., Roberts S. Deep reinforcement learning for trading //arXiv preprint arXiv:1911.10107. – 2019.
- 40.Жизнь облигаций после размещения [Электронный ресурс]. URL: <https://bondguide.moex.com/articles/life-bonds-after-placement/48#head-0> (дата обращения: 23.03.2025).
- 41.Машинное обучение в алгоритмической торговле на бирже [Электронный ресурс]. URL: <https://habr.com/ru/articles/561746/> (дата обращения: 23.03.2025).

42.Обучение с подкреплением для трейдинга [Электронный ресурс]. URL:
<https://habr.com/ru/companies/skillfactory/articles/717360/> (дата
обращения: 23.03.2025).

Приложения

Приложение 1.

Дескриптивная статистика по основным колонкам тренировочного датасета сегмента 1.

	bid_price_1	bid_volume_1	ask_price_1	ask_volume_1
count	1,488,331	1,488,331	1,488,330	1,488,331
mean	68.7	2525.4	68.9	260.1
std	0.7	1094.1	45778	190.5
min	64.3	1.0	65.0	1.0
25%	68.5	2000.0	68.5	120.0
50%	69.0	3000.0	69.0	240.0
75%	69.0	3000.0	69.0	380.0
max	69.0	4000.0	69.5	1000.0

Дескриптивная статистика по основным колонкам валидационного датасета сегмента 1.

	bid_price_1	bid_volume_1	ask_price_1	ask_volume_1
count	187,841	187,841	187,841	187,841
mean	68.9	2800.0	69.1	290.2
std	0.3	150.0	0.1	130.8
min	68.5	2500.0	69.0	50.0
25%	68.8	2700.0	69.0	200.0
50%	69.0	2800.0	69.0	280.0
75%	69.0	2900.0	69.0	360.0
max	69.2	3200.0	69.2	600.0

Дескриптивная статистика по основным колонкам тестового датасета сегмента 1.

	bid_price_1	bid_volume_1	ask_price_1	ask_volume_1
count	328440	328440	328440	328440
mean	62.19	2800.0	62.21	310.5
std	10959	180.0	11324	126.2
min	59.97	2400.0	60.00	50.0
25%	61.10	2700.0	61.12	230.0
50%	62.30	2800.0	62.31	300.0
75%	63.40	2900.0	63.42	370.0
max	64.41	3200.0	64.42	600.0

Дескриптивная статистика по основным колонкам тренировочного датасета сегмента 2.

	bid_price_1	bid_volume_1	ask_price_1	ask_volume_1
count	963,629	963,629	963,628	963,629
mean	72.5	1828.1	72.6	310.4
std	0.7	507.0	0.4	120.3
min	69.0	1.0	71.5	1.0
25%	72.3	1600.0	72.4	220.0
50%	72.7	1972.0	72.7	300.0
75%	72.7	1972.0	72.7	390.0
max	72.7	4000.0	73.0	800.0

Дескриптивная статистика по основным колонкам валидационного датасета сегмента 2.

	bid_price_1	bid_volume_1	ask_price_1	ask_volume_1
count	114,252	114,252	114,252	114,252
mean	72.6	1850.0	72.8	310.2
std	0.2	100.0	0.1	120.6
min	72.4	1600.0	72.7	50.0
25%	72.5	1800.0	72.7	220.0
50%	72.6	1900.0	72.8	300.0
75%	72.7	1972.0	72.8	390.0
max	72.8	2100.0	72.9	800.0

Дескриптивная статистика по основным колонкам тестового датасета сегмента 2.

	bid_price_1	bid_volume_1	ask_price_1	ask_volume_1
count	166,145	166,145	166,145	166,145
mean	64.75	1850.0	64.76	310.2
std	0.21	100.0	0.22	116.1
min	64.40	1600.0	64.41	50.0
25%	64.62	1800.0	64.63	220.0
50%	64.75	1900.0	64.76	300.0
75%	64.89	1972.0	64.90	390.0
max	65.11	2100.0	65.12	800.0

Дескриптивная статистика по основным колонкам тренировочного датасета сегмента 3.

	bid_price_1	bid_volume_1	ask_price_1	ask_volume_1
count	10,330,422	10,330,422	10,330,422	10,330,422

mean	3433.1	45.9	3433.3	48.2
std	111.0	50.2	111.2	55.1
min	3025.0	1.0	3025.1	1.0
25%	3350.0	10.0	3350.1	12.0
50%	3430.0	28.0	3430.1	30.0
75%	3490.0	70.0	3490.2	72.0
max	3570.0	1000.0	3600.0	2000.0

Дескриптивная статистика по основным колонкам валидационного датасета сегмента 3.

	bid_price_1	bid_volume_1	ask_price_1	ask_volume_1
count	700,993	700,993	700,993	700,993
mean	3490.1	40.2	3490.3	43.1
std	107.3	60.1	116.8	55.4
min	3486.5	1.0	3486.7	1.0
25%	3489.0	10.0	3489.1	15.0
50%	3490.0	28.0	3490.1	30.0
75%	3491.0	60.0	3491.2	65.0
max	3495.0	1000.0	3496.0	1500.0

Дескриптивная статистика по основным колонкам тестового датасета сегмента 3.

	bid_price_1	bid_volume_1	ask_price_1	ask_volume_1
count	109,785	109,785	109,785	109,785
mean	3146.5	32.0	3146.7	35.8
std	45790	45740	45821	45805
min	3123.0	1.0	3123.1	1.0
25%	3134.0	10.0	3134.2	12.0
50%	3146.0	28.0	3146.2	30.0
75%	3158.0	55.0	3158.1	58.0
max	3170.0	1000.0	3170.5	1500.0